

面向国产硬件极致性能优化的推理引擎项目测试 方案

课 题 编 号	2025ZD0123804
课 题 名 称	面向国产硬件极致性能优化的推理引擎
课 题 负 责 人	张书豪
课 题 承 担 单 位	华中科技大学
执 行 期 限	2025 年 12 月—2028 年 11 月

浦江国家实验室制

2026 年 8 月 21 日

目 录

1 依据文件	4
2 基本情况	5
2.1 项目简介	5
2.2 测试目的	5
2.3 测试范围	5
3 测试环境	6
3.1 软硬件环境	6
3.2 测试场地	7
3.3 测试数据	7
4 测试内容与方法	8
4.1 必须交付：任务书四项考核指标	10
4.2 必须交付：结果有效性检查	12
4.3 额外交付：核心技术路线核验	13
4.4 企业数据集与补充压力数据纳入要求	13
4.5 固定模型、负载与部署配置矩阵（含必须与额外）	17
4.6 测试方法与结果判定	24
4.7 本课题测试交付与第三方评测	34
5 测试风险分析	35
6 测试工作安排	36
6.1 测试进度	36

6.2 人员与职责	36
附：正式测试配置冻结表	38

1 依据文件

本方案对应《面向国产硬件的软硬协同训推关键技术与系统》项目任务书（所属项目编号：2025ZD0123800）中的课题4《面向国产硬件极致性能优化的推理引擎》（以下简称“本项目”），重点落实该课题第4.4节、表2-11及进度安排规定的考核指标、评测方式、阶段成果和最终交付要求。任务书的正式变更文件与本方案共同构成本项目测试依据。

本方案的适用对象仅为本项目研制的vLLM-HUST推理引擎及其部署、测试和验收交付。本方案不承接所属总项目其他课题的训练系统、后训练框架、仿真环境服务或集成平台交付物，也不以其他课题指标替代本项目验收指标。

测试文档编制和实施同时参照GB/T 9386-2008、GB/T 15532-2008、GB/T 38634.1-2020及GB/T 25000.51-2016。华为云acs-bench推理性能测试实践和EvalScope模型推理性能压测文档，仅作为负载生成、并发爬坡、SLO goodput、分位数统计和结果采集的工具参考，不构成本项目基准测试或验收规则。公开基准测试采用官方发布版本、任务/数据、评价程序和指标；企业数据集与synthetic/hybrid数据只作为测试数据，按照授权、脱敏、生成、留存和删除要求使用，不因被回放而转化为基准测试。

本方案正文、附表及随方案归档的测试目标登记表共同构成正式验收依据，芯片与拓扑、模型工件、数值精度、基准软件、测试配置、数据选择规则、负载形状、SLO、指标口径、运行程序、启动参数和阈值统一执行。代码提交、镜像摘要、物理设备号、实际命令、配置校验值和运行回执作为执行记录纳入证据包。固定值不完整或执行记

录与本方案不一致时，不得进入正式测量。任务书正式变更文件按变更控制程序纳入新版本方案。

2 基本情况

2.1 项目简介

本课题面向国产 AI 芯片研制 vLLM-HUST 推理引擎，测试对象包括引擎软件、固定模型工件及其部署配置，验收以任务书 A1—A4 和第三方可复核证据为依据。

2.2 测试目的

本方案用于验证 vLLM-HUST 在国产 AI 芯片上的推理性能、长上下文稳定性、单位 token 成本和工程可部署性，并形成可供第三方执行和复核的测试依据。测试对象是推理引擎及其部署配置，不以模型知识能力高低替代引擎性能结论。

2.3 测试范围

表 2-1 完成级别、评价类别及结论效力

完成级别	评价类别	范围	结论效力
必须交付	任务书 A1—A4	Qwen2.5-14B 单卡；P0 及 A1—A4 均执行 B0-FP16/B1-FP16；通用问答/多轮、工具调用、推理、结构化输出、长上下文、代码；A2-V 模态适用性；完整证据包	形成通过/不通过/不具备判定条件；W8A8 缺失不阻塞 FP16 必测结论
额外交付	能力与亮点	W8A8 系统交付扩展；Qwen3.6-27B 双卡同 6 类可执行负载；DSV4 高 KV 复用/代码；Kimi 多模态/Agent 工具/AI4Science 及代码 Agent	形成完成/未通过/未执行；不得阻塞或替代必须交付

本方案只设“必须交付”和“额外交付”两个层级。必须交付以完成任务书 A1—A4 并形成第三方可判定证据为第一优先级，固定 Qwen2.5-14B 单卡为主验收模型；Qwen3.6-27B 双卡复用同一组业务

负载但属于额外交付，DSV4 单机 8 卡和 Kimi K2.6 多机承担扩展能力。额外交付不得替代、冲抵或延后必须交付。任务书规定代表模型范围为 7B—13B；Qwen2.5-14B 作为本次验收的等效代表模型。

验收结论

必须交付部分形成 A1—A4 任务书指标结论，结论为“通过/不通过/不具备判定条件”。四项指标、必要正确性检查和证据链全部满足后方可判定通过。额外交付按实际执行项形成“完成/未通过/未执行”结论，只用于能力边界和亮点说明，不影响必须交付结论。

3 测试环境

3.1 软硬件环境

表 3-1 测试对象与冻结要求

对象	基本要求	正式测试前冻结内容
国产 AI 芯片	同规格 910B2；卡数按测试配置冻结	芯片型号、卡数、拓扑、理论峰值、驱动和固件；主机名和机架位置不作为趋势分组维度
四个固定模型	Qwen2.5-14B 、 Qwen3.6-27B 、 DeepSeek V4 Flash、 Kimi K2.6	Qwen2.5 固定 FP16 源工件； W8A8 扩展工件独立登记；其余模型固定仓库、版本、权重/tokenizer 校验值、精度和上下文长度
引擎对照	B0=固定 vLLM 0.18； B1=固定优化版本；必测比较=B0-FP16 对 B1-FP16； W8A8 为独立扩展	B0/B1 exact refs 见本方案；两侧镜像摘要、实际 CLI、配置校验值和生效回执进入证据包
数据与负载	公开基准测试、固定子集、企业回放和受控负载形状分别登记	授权、样本标识、版本、顺序、随机种子、内容/token 校验值、判定规则和解析器

对象	基本要求	正式测试前冻结内容
执行配置	每个 profile_id 提供 B0、B1 各自部署方式和启动 YAML，并绑定同一规范化配置与外部测试合同	保存两侧原始 YAML、规范化配置、环境变量和生效回执；FP16 必测线除代码、镜像和角色标识外逐字段相同
启动参数合同	每个正式 profile 建立机器可读且不可变的共同启动参数和客户端合同	保存 comparison_type、comparison_id、各角色 config_id、FP16/W8A8 工件清单、缓存/图执行/推测解码生效回执和合同核验记录
证据包	配置标识、测试单元标识与解析后配置校验值一一对应	原始请求、聚合结果、日志、来源记录、重复试验记录、签名和校验清单

3.2 测试场地

正式性能测试在独立评测环境中执行，由第三方测试机构控制测试流程并独占所需 910B2 资源。持续集成系统仅提交测试请求，不直接占用加速卡。

3.3 测试数据

测试数据采用可公开核验或具有合法授权的数据资产，并按 A1 固定形状与基础服务、A2 通用问答/多轮、工具/Agent、推理、结构化输出、代码、长上下文及多模态适用性、A3 长上下文/KV 压力、A4 五租户混合调度组织。每个指标配置绑定一组符合合同的数据集，不设唯一指定数据集，也不按来源设置主数据集、备选或替代等级。同一物理资产只保存一份，跨 A 项、单元和租户通过 manifest 引用。数据执行档位为 REQUIRED/SUPPLEMENTARY，指标交付档位为 REQUIRED/ADDITIONAL，两者分别冻结、不得混用。正式 config_id 生成前冻结 dataset_id、test_tier、contract_role、coverage_role、许可、

版本、样本顺序、转换程序和 token 校验值；之后不得根据 B0/B1 结果换题或改档。

4 测试内容与方法

正式测试配置是最小判定单元。A1—A4 必须交付统一执行 B0-FP16 与 B1-FP16 同规格对照；通用问答/多轮另执行所选数据资产完整指定分片的全量对照 P0。W8A8 属于系统交付扩展 P2：仅在不可变 W8A8 工件、质量回执和对应运行环境齐全时执行，不阻塞 FP16 必测结论。B0 无需修改代码即可加载同一 W8A8 工件时，增加 B0-W8A8 与 B1-W8A8 同量化对照；否则分别报告 B1-W8A8 相对 B1-FP16 的量化增量以及 B1-W8A8 相对 B0-FP16 的端到端系统结果，不将后者表述为纯引擎优化收益。A2 包含通用问答/多轮、工具调用、推理、结构化输出、长上下文和代码 6 个独立执行单元；A2-V 对当前文本模型只执行资产及模态适用性检查，不产生通过结果。

表 4-1 验收配置及结论归属

配置名称	层级	模型/拓扑	绑定内容	结论用途
A1 单卡有效算力配置	必须	Qwen2.5-14B；单卡	4096×8 主 Prefill； 1024×32、8192×4 辅助	A1 有效算力
A2 典型场景性能配置	必须	Qwen2.5-14B；单卡	6 个独立 FP16 profile： 通用问答/多轮、工具调用、推理、结构化输出、长上下文、代码； A2-V 另作模态适用性检查；各单元绑定数据集组 manifest；W8A8 另作扩展	A2 性能与能力证据
A3 长上下文稳定性配置	必须	Qwen2.5-14B；单卡	B0/B1 FP16；授权长文本 data_profile_id； 30720+2048；30 分钟	A3 长上下文门禁

配置名称	层级	模型/拓扑	绑定内容	结论用途
A4 多租户成本配置	必须	Qwen2.5-14B; 单卡	B0/B1 FP16; 通用问答/多轮、工具/Agent、推理、结构化输出、代码五租户; 启用前缀缓存	A4 成本与利用率
Qwen3.6 双卡扩展配置	额外	Qwen3.6-27B; 双卡	与 Qwen2.5 相同 6 类可执行负载和数据集组协议; 独立容量/SLO; 多模态另按模型能力执行	双卡能力, 不跨模型比较
DeepSeek V4 Flash 扩展配置	额外	DeepSeek V4 Flash; 单机 8 卡	高 KV 复用; 标准代码服务	KV/MoE/代码亮点
Kimi K2.6 多机扩展配置	额外	Kimi K2.6; 多机	多模态、Agent/工具、AI4Science; 代码长程 Agent 测试配置	多机与复杂 Agent 亮点

B0 固定为 upstream vLLM 0.18 基准：core 提交 bcf2be96120005e9aea171927f85055a6a5c0cf6, vLLM-Ascend 插件提交 e18643f8a4d5bd9990727654318ad069ea0b56e2, 运行于 Ascend v0.23 代容器和 CANN 9.1 环境。B1 固定为本次正式优化验收版本：core 提交 1a06c55468966de8ef471ecb7612c199e15a153a, vLLM-Ascend 插件提交 ac2b94f1536090e2cd0d6c2f8bc8087e336193d5。P0 和 A1—A4 必测线均为 B0-FP16 与 B1-FP16; 硬件、模型、精度、数据、请求、到达序列、采样、SLO、测量周期、服务配置和图执行逐项相同, 只允许代码提交、对应镜像身份和角色标识不同。A1 两侧均使用 eager; P0 及 A2—A4 两侧均使用 FULL_DECODE_ONLY 和相同 capture sizes。W8A8 扩展严格执行表附-1 固定角色合同, 除模型工件、服务名称和 quantization 三项固定取值外, 其余字段逐项一致, 不得现场增加其他差别或例外。

4.1 必须交付：任务书四项考核指标

表 4-2 任务书考核指标、测试方法与通过要求

编号	考核指标	精确执行合同	通过要求	主要证据
A1	单芯片有效算力	主形状：输入 4096 token、批量 8；辅助形状：输入 1024 token、批量 32 和输入 8192 token、批量 4；输出 1 token；FP16；张量/流水/数据并行均为 1；最大模型长度 32768；显存利用率 0.85；关闭前缀缓存和分块预填充；最大序列数 32；单批最大 token 数 32768；预热 10 轮、测量 30 轮	主形状达到 910B2 设备 FP16 峰值分母的 90%以上；峰值分母取 ascend-dmi 三次独占测量中位数；effective_compute_spec v1 与 msprof 误差不超过 3%	算量规范、ascend-dmi 输出、性能分析与计数器记录、同步墙钟时间、3 次独立生命周期
A2	典型场景性能	A2 含 6 个独立 FP16 执行单元。每个单元按表 4-5 绑定数据集组 manifest；同组多个 REQUIRED 数据集分别执行、分别报告。通用问答/多轮执行 P0 和容量扫描；工具、推理、结构化输出、代码按冻结官方 split 和 scorer 执行；长上下文执行固定形状。A2-V 对文本模型只作模态适用性检查。B0/B1 均启用相同 FULL_DECODE_ONLY 配置。	通用问答/多轮和工具调用： B1-FP16/B0-FP16 最大合规吞吐≥2 倍； 共同负载平均 TTFT 和平均 TPOT 均改善≥20%； 其余单元按质量、错误和容量边界判定	逐请求记录、容量曲线、SLO 合规吞吐、质量判定、错误记录和 B0/B1 对照结果

编号	考核指标	精确执行合同	通过要求	主要证据
A3	32K 长上下文稳定性	B0/B1 FP16; 授权长文本 data_profile_id; 总上下文 32768=输入 30720+输出 2048; 并发 1; 闭环; 预热 5 分钟、测量 30 分钟; 6 个 5 分钟窗口; 最多 64 请求且至少完成 24; 重复 3 次	0 失败; 无 OOM、死锁、退出或静默截断; 窗口吞吐 $CV \leq 5\%$; 各窗口 TTFT/TPOT 中位数相对首个稳定窗口漂移 $\leq 10\%$, p99 漂移 $\leq 20\%$	LONG-PUBLIC 请求清单、输入/输出 token 回执、窗口统计、HBM/KV 监控、服务与请求日志
A4	成本与多租户利用率	B0/B1 FP16; 通用问答/多轮、工具/Agent、推理、结构化输出、代码五类冻结请求按投递输出 token 各 20%; 固定点扫描 B0 容量后在 70%共同负载对照; 泊松到达、每租户并发 4、全局 16; 预热 5 分钟、测量 30 分钟	B1-FP16 单位 token 成本较 B0-FP16 降低 $\geq 30\%$; Jain ≥ 0.90 ; 份额偏差 $\leq 10\%$; p99 $\leq$ 隔离 B0 1.25 $\times$; 样本 < 1000 时 0 失败; 单卡平均利用率 $\geq 60\%$	全生命周期成本、成功 token、租户 SLO/份额、设备利用率、同周期价格

A1—A4 执行合同见表 4-2。A1 使用 FP16，910B2 FP16 峰值分母在独占设备上执行 3 次测量并取中位数，effective_compute_spec 与 msprof 误差不超过 3%。A2—A4 必须执行 B0-FP16 和 B1-FP16；通用问答/多轮和工具调用按 B1-FP16 相对 B0-FP16 判定最大合规吞吐不低于 2 倍、共同负载平均 TTFT 和平均 TPOT 均改善 20%以上。A3 独立承担 32K 稳定性验收，总上下文固定为 32768 token，其中输入 30720 token、输出 2048 token。A4 按同一 FP16 比较完成成本、公平性、利用率和尾延迟判定。W8A8 扩展在工件齐全且通过质量门禁后另行形成结果，不替代 FP16 必测线。每个正式阶段至少执行 3 次独立生命周期，按预声明主指标中位数判定，完整保留失败、超时和追加复测。

4.2 必须交付：结果有效性检查

表 4-3 正式结果有效性检查

检查项	检查内容	通过要求	不通过处理
协议与接口	聊天与多轮协议、OpenAI 兼容的结构化输出协议、真实工具定义及自动工具选择协议	字段完整；无协议降级；工具名称与参数能够按冻结判定规则核验	修复后完整重跑受影响测试单元
质量	推理答案、Schema 合法性、工具名称和参数、代码编译/单测、长文本输出	推理、结构化输出、工具调用、代码和长文本的 B1 质量较 B0 下降不超过 1 个百分点；Schema 合法率 100%；结构化输出和工具调用任务成功率不低于 95%；代码按冻结官方 scorer 判定	对应测试单元不通过，不得以性能结果抵消
量化工件质量	W8A8 扩展工件相对同源 B1-FP16 的推理、Schema、工具和长文本质量	推理、工具、结构化和长文本任务成功率下降均不超过 1 个百分点；Schema 合法率 100%；工具和结构化任务成功率不低于 95%	不合格工件不得进入 W8A8 扩展；FP16 必测线照常执行并形成结论
优化机制生效性	前缀缓存、分块预填充、B0/B1 图执行和可选 W8A8 量化加载；额外交付另核验 Qwen3.6 MTP	启动回执与运行指标证明表附-3 规定的机制实际生效；两侧保存图捕获尺寸、捕获次数、命中次数、回退次数和编译耗时；缓存单元保存查询、命中和逐请求前缀身份	机制未生效或指标缺失时对应单元无效，修复后从第一轮完整重跑
运行正确性	全部成功、失败、超时、取消、重试和静默截断请求	错误率不超过 0.1%；样本不足 1000 时要求 0 失败；无数据损坏	保留失败记录并完整复测
启动参数一致性	逐项比较 B0、B1 原始命令/YAML、规范化配置、环境变量、客户端合同和实际生效值	B0-FP16 与 B1-FP16 除代码、镜像和角色标识外全部性能字段一致；W8A8 扩展只允许固定工件、服务名和 quantization 变化；所有其他字段一致	任一参数不一致、隐式默认、字段缺失、图未捕获或生效值不符时不得测量；修订后完整重跑

检查项	检查内容	通过要求	不通过处理
因果与规格	同一比较使用相同硬件、模型精度、数据、请求、到达序列、SLO 和共同最佳支持图配置；不得人为关闭任一侧正式支持的优化	精确版本、镜像、模型/量化工件、数据、请求合同和共同配置可追溯	缺失或冲突时不得形成验收结论；定位运行属于验收外工程活动，不得进入验收证据

4.3 额外交付：核心技术路线核验

核心技术路线核验属于额外交付。DeepSeek V4 Flash 验证高 KV 复用与标准代码服务；Kimi K2.6 验证多模态、Agent/工具调用、AI4Science，并可在代码负载下增加长程代码 Agent 配置。Qwen 的必验工具调用不得由 Kimi 额外结果替代。PD、EP、KV 或压缩亮点均须提供开关对照、机制生效记录、时间线和原始结果。

表 4-4 核心技术路线核验要求

编号	核心机制	对照配置	通过要求	主要证据
M1	PD 分离	同模型/硬件/精度/负载下关闭与开启；分别覆盖 Prefill/Decode 主导流量	质量和错误率合格；同 SLO goodput 或目标时延有可重复收益；不得只证明可启动	阶段队列、P/D 吞吐、路由与 KV 传输、时间线、请求级结果
M2	KV 池化、分层与复用	冻结共享前缀、会话复用、hit/miss 比例；命中/未命中分开	命中路径 TTFT 或 Prefill 计算时间下降 $\geq 20\%$ ；未命中路径关键时延回退 $\leq 5\%$ ；无串扰	命中/驱逐/迁移日志、KV 占用、正确性判定规则、时间线
M3	进一步压缩与调度协同	在 A2—A4 可选 W8A8 扩展之外，额外比较 W4A8、KV FP8 或其他压缩方案；每种方案使用独立工件和独立 profile，不替换 FP16 必须交付结果	质量合格，且每 token 显存下降 $\geq 20\%$ 或全系统单位 token 成本下降 $\geq 15\%$	工件哈希、精度/格式、质量、显存、吞吐/时延和成本

4.4 A1—A4 指标与数据资产矩阵

A1—A4 数据与指标矩阵冻结于 vLLM-HUST/dev-hub 提交 91bcc4154b70333d87c8180afe85dc933452e253。物理注册表去重为 44

个数据集或请求轨迹家族；a1-a4-metric-dataset-matrix.csv 固定 19 项必须指标和 10 项附加指标。每个数据集只在适用指标中填值：不适用填 N/A 并给出原因；适用但资产、许可、oracle、模态或资格条件缺失时填具体阻塞状态并将对应结论记为 CANNOT_DETERMINE，不得填 0。表 4-5 及完整数据集测试矩阵决定执行适用性；物理注册表的 A1_A4_scope 仅用于资产索引，不得覆盖指标配置引用。派欧云 8 项按表 4-7 登记；BFCL v4、tau2-bench、ToolBench 和 StructEval 按冻结官方发布执行。多个数据集分别出具结果，不加权平均掩盖失败。

表 4-5 A1—A4 指标配置与数据集组

指标配置	数据集组	冻结数据资产系列	档位与适用性	执行规则
A1 固定形状与基础服务	A1-COMPUTE	tokenizer-exact synthetic、vLLM random、sonnet、 random-latency、 logprobs、 spec-decode； PAIO-LONG-PR EFILL 与 PAIO-PREFIX-S HARED 按规定 作补充	固定形状与基础路径为 REQUIRED；两项派欧机 制运行按表 4-7 分档	4096×8 为唯一 MFU 主形状；各生 成器、种子和请求 manifest 冻结；不 得用自然语料替换 固定 token 形状

指标配置	数据集组	冻结数据资产系列	档位与适用性	执行规则
A2-D 通用问答/多轮	DIALOGUE-GROUP	ShareGPT V3 、 UltraChat 200K 、 OASST1 、 LMSYS-Chat-1M 、 WildChat 、 WildChat-4.8M 、 PAIO-CHAT 、 PAIO-REUSE-CO NV ； PAIO-SEMANTI C-SIMILAR 单列	适用且资产齐全的 REQUIRED 数据分别执 行；语义相似项为 SUPPLEMENTARY	保留完整官方 split 和会话边界； LMSYS 未授权时保 留 AUTH_REQUIRE D；不得把单轮数 据冒充多轮
A2-T 工 具 /Ag ent	TOOL-GROUP	BFCL v3 、 BFCL v4 、 tau2-bench 、 ToolBench 、 EvoScientist 、 SyFi 、 HotpotQA/ReAct 、 agent-cache-press ure ； OpenCode/SWE-b ench 轨迹单列扩 展	REQUIRED 数据分别执 行；生产优化扩展不替代 BFCL/tau2	真实 tools 协议；冻 结官方 oracle/parser、任务 状态和工具环境； BFCL v4 使用 bfcl-eval==2025.12 .17； ToolBench 使 用完整 G1/G2/G3 及 test split
A2-R 推 理	REASON-GROUP	GSM8K main/socratic 、 MATH-500 、 GPQA 、 BBH 、 MMLU-Pro、 AI2 ARC 、 AIME 2024、 HotpotQA、 LongBench-v2 ； PAIO-CODE-EV AL 作性能证据	有冻结 oracle/scorer 者 REQUIRED ； PAIO-CODE-EVAL 缺 gold 时正确率 N/A	完整官方 split 分别 执行；答案抽取失 败、空响应、超时 均计失败；许可缺 失不得伪造完成

指标配置	数据集组	冻结数据资产系列	档位与适用性	执行规则
A2-S 结构化输出	STRUCT-GROUP	SchemaStore 、JSONSchemaBench、StructEval、BFCL 参数 JSON 、PAIO-JSON-500	适用且资格齐全者 REQUIRED	逐 schema 记录 dialect 与外部引用；Schema 和任务成功率分别报告；PAIO-JSON 不含 tools
A2-C 代码	CODE-GROUP	InstructCoder 、LiveCodeBench 三类 split 、HumanEval 、MBPP 、SyFi 、PAIO-CODE-EVAL ；OpenCode/SWE-bench 轨迹单列扩展	官方代码数据为 REQUIRED；PAIO-CODE 扩展引用不重复物理文件	使用冻结编译器、容器、测试用例与官方 scorer；每个数据集分别报告通过率、TTFT、TPOT 和吞吐
A2-V 多模态适用性	VISION-GROUP	VisionArena-Chat 冻结 parquet 及图像引用	当前 Qwen2.5 文本模型为 MODEL_MODALITY_NOT_APPLICABLE	不得转成纯文本冒充多模态；资产保留但不产生通过结果；具备相同图像协议的 B0/B1 模型方可执行
A3 长上下文/KV 压力	LONG-KV-GROUP	LongBench 、LongBench-v2 、InfiniteBench 、RULER 、BFCL long 、SyFi 、OASST1 、KV/prefix 生成器 、PAIO-LONGTEXT	适用且资产齐全者 REQUIRED；资格未完成者 CANNOT_DETERMINE	按 4K/8K/16K/32K 和 A3 固定 30720+2048 分别执行；超出模型上限 记 UNSUPPORTED，不静默截断
A	A4-TENANT	引用 A2 的	五 租 户	不另建数据

指标配置	数据集组	冻结数据资产系列	档位与适用性	执行规则
4 五 租 户 混 合	-GROUP	Dialogue 、 Tool/Agent、 Reasoning、 Structured、 Code 同一 物理资产； BurstGPT 与 SyFi 提供 到达 / 会话 trace	REQUIRED；不适 用的硬件或模型扩 展明确记 N/A	副本；每个 dataset_id 保 留 record/sessi on/tenant 标 签；按投递输 出 token 各 20%，逐租户 分别出具质 量与性能

企业数据集执行前应登记记录数、字段结构、数据授权、脱敏状态、适用主机、保留期限和 SHA-256 校验值。原始请求仅保存在授权环境；第三方报告使用脱敏样例、汇总指标和不可逆标识。静态 JSONL 不含真实到达时间时，统一采用表附-6 规定的到达率、并发和 vllm-hust-poisson-v1 到达序列生成规则，不得将生成的到达过程表述为企业真实流量轨迹。synthetic/hybrid 补充压力数据同时记录生成器版本、参数、种子、目标分布和校验值。

4.5 固定模型、负载与部署配置矩阵（含必须与额外）

4.5.1 负载覆盖与模型绑定

模型与负载采用一对多绑定。Qwen2.5-14B 单卡与 Qwen3.6-27B 双卡绑定相同 6 类可执行负载：通用问答/多轮、工具调用、推理、

结构化输出、长上下文和代码；前者必须验收，后者额外交付，并分别冻结容量、SLO 和结论，禁止跨模型比较。VisionArena 归入 A2-V 模态适用性检查，当前 Qwen2.5-14B 文本模型记为 MODEL_MODALITY_NOT_APPLICABLE，不计通过。Qwen2.5 的 A1—A4 必测线使用 FP16；W8A8 作为同源量化扩展。DeepSeek V4 Flash 绑定高 KV 复用与代码；Kimi K2.6 绑定多模态、Agent/工具调用、AI4Science 和长程代码 Agent。A1—A4 仍是唯一任务书结论。

表 4-6 九类负载、测试数据与模型绑定

负载	交付层级	评价方式	固定模型/拓扑	执行边界
通用问答/多轮	必须；额外	冻结对话数据集组、P0 全量对照与服务容量	Qwen2.5 单卡； Qwen3.6 双卡	A2 性能合同项
工具调用	必须；额外	BFCL v3/v4 、 tau2-bench 、 ToolBench 等真实工具与 Agent 任务	Qwen2.5 单卡； Qwen3.6 双卡； Kimi 多机	Qwen 为 A2 性能锚点；Kimi 为复杂 Agent 扩展，不能替代
推理	必须；额外	冻结官方答案/scorer；各数据集分别报告质量与性能	Qwen2.5 单卡； Qwen3.6 双卡	A2 质量与能力证据项
结构化输出	必须；额外	SchemaStore 、 JSONSchemaBench、StructEval、BFCL 参数 JSON 及企业 JSON	Qwen2.5 单卡； Qwen3.6 双卡	A2 质量与能力证据项；不得替代工具调用测试
长上下文	必须；额外	A2 容量曲线；A3 LongBench/InfiniteBench/RULER 及 30720+2048 长稳	Qwen2.5 单卡； Qwen3.6 双卡	A2 仅报告容量边界；A3 承担长上下文验收

负载	交付层级	评价方式	固定模型/拓扑	执行边界
高 KV 复用	额外	缓存开启/关闭对照、命中与驱逐记录、HBM 占用和正确性判定	DSV4 单机 8 卡	不进入 Qwen A2/A4
代码	必须；额外	InstructCoder、LiveCodeBench、HumanEval、MBPP、SyFi 及企业代码评判；冻结编译/单测/scorer	Qwen2.5 单卡； Qwen3.6 双卡； DSV4 单机 8 卡； Kimi 多机	A2 代码能力证据及 A4 Code 租户；DSV4 标准代码和 Kimi 长程代码 Agent 为额外配置
多模态	必须适用性检查；额外	VisionArena 冻结图文资产及评价程序	Qwen2.5 文本模型；Kimi K2.6 多机	Qwen 文本模型记 MODEL_MODALITY_NOT_APPLICABLE, 不算通过；Kimi 支持图像协议后执行
AI4Science	额外	冻结科学任务与端到端完成率	Kimi K2.6 多机	真实完成任务才形成结论
公共 9 项健康线	工程夜间回归	预声明主指标与同规格趋势	独立评测服务的固定工程目标	不是任务书必测，不阻塞项目验收

4.5.2 权威基准与固定测试配置说明

正式数据按完整指定分片或执行前固化的资格规则处理，不从正式结果中择优抽样。Qwen2.5 与 Qwen3.6 复用同一 data_profile_id、确定性转换协议、负载形状、随机种子、请求顺序和判定程序，但独立进行容量测试。企业 JSONL 按授权数据标识，不表述为公开基准。每项测试保存数据版本、有序内容校验值、tokenizer 校验值、评价程序和原始响应。

表 4-7 派欧云企业场景数据清单及 A1—A4 归属

数据配置	来源、规模与性质	A1—A4 归属	纳入方式与边界
PAIO-CHAT-1000	派欧云接口请求 1000 条；通用问答、写作、总结、分类和客服模拟；以单轮请求为主	A2 通用问答补充；A4 问答租户补充	用于企业场景容量和稳定性回放；不替代 P0 不少于 20000 条及多轮合同；重写 model、max_tokens 等字段后生成独立 data_profile_id
PAIO-CODE-EVAL-1000	派欧云流式代码评判请求 1000 条；输出目标以短分类结果为主	A2 推理/时延补充；A4 推理租户补充；代码额外负载	可用于 TTFT 和短输出性能；缺少独立 gold 时不得承担推理质量主判；不得归入工具调用
PAIO-JSON-500	派欧云结构化请求 500 条；328 条 json_object、172 条 json_schema	A2 结构化输出补充；A4 结构化租户补充	全部请求执行 JSON 及 Schema 合法性检查；统一为本方案固定 endpoint、采样和输出上限；不含 tools 协议
PAIO-LONG-PREFILL-5000	混合合成长 Prefill 5000 条；估算输入 10670—22794 token，目标输出 96—768 token	A1 代表性补充；A2 长上下文容量	A1 仅补充内容代表性，不替代 4096×8 主形状和 MFU 判定；A2 按固定 tokenizer 确定性窗口化；因长度不足不承担 A3 主判
PAIO-PREFIX-SHARED-5000	混合合成共享前缀 5000 条；估算输入 3770—8762 token	A1/A2 机制补充；A1—A4 不计硬门槛	用于前缀缓存开关对照及高 KV 复用额外负载；结果单列，不改变 Qwen 必测矩阵
PAIO-REUSE-CONV-5000	混合合成会话复用 5000 条；含高、中、低复用层级	A2 问答补充；A4 问答租户补充；高 KV 复用额外负载	按复用层级分层报告，不按结果筛选；合成属性必须随结果披露
PAIO-SEMANTIC-SIMILAR-5000	混合合成语义相似请求 5000 条；估算输入 2826—7263 token	A2/A4 扩展，不参与 A1—A4 硬门槛	用于语义相似、缓存误命中和混合批稳定性分析；不得表述为真实线上 trace

数据配置	来源、规模与性质	A1—A4 归属	纳入方式与边界
PAIO-LONGTEXT-4000	派欧云 API 生成文本 4000 条；字符长度 29952—140646；精确 token 长度执行前计算	A2 长上下文容量；满足资格条件后用于 A3 32K	按固定 tokenizer 和内容 hash 确定性选择并生成 8192/16384 及 30720 输入；完成授权、敏感信息扫描、目标事实和 oracle 核验后方可进入正式 data_profile

4.5.3 模型族、规模层级与冻结

正式矩阵只使用四个模型：Qwen2.5-14B 单卡、Qwen3.6-27B 双卡、DeepSeek V4 Flash 单机 8 卡、Kimi K2.6 多机。Qwen2.5-14B 为必须验收指定模型，其余三个为额外交付。Qwen2.5 的 FP16 工件固定 revision、完整权重和 tokenizer 校验值；B0 与 B1 均使用逐字节相同的 FP16 工件。W8A8 工件作为可选系统交付扩展，必须由该 FP16 源工件生成并单独绑定量化配置和完整 SHA-256 清单，第三方不得现场重量化。

表 4-8 模型分层与冻结要求

层级	冻结模型工件	拓扑	绑定负载	实施要求
必须	Qwen2.5-14B	单卡	问答/多轮、工具调用、推理、结构化、长上下文；A1—A4	优先启用；A1—A4 必测为 B0/B1 FP16；W8A8 为独立扩展；工作负载专属配置见表附-3
额外	Qwen3.6-27B	双卡	与 Qwen2.5 相同 6 类可执行负载	固定 W8A8 双卡配置：TP=2、PP=1、DP=1、gmu=0.90、max_model_len=32768、max_num_seqs=32、max_num_batched_tokens=8096、prefix=false、chunked=true、quantization=ascend、MTP=qwen3_5_mtp/3、cudagraph=FULL_DECODE_ONLY、async_scheduling=true；复用 6 类数据协议并独立形成容量、SLO 和结论

层级	冻结模型工件	拓扑	绑定负载	实施要求
额外	DeepSeek V4 Flash	单机 8 卡	高 KV 复用、标准代码服务	张量/专家并行方式、KV Cache 精度、前缀长度和显存利用率须在启用前写入本方案配置表，缺失时不执行
额外	Kimi K2.6	多机	多模态、Agent/工具、AI4Science；长程代码 Agent 测试配置	冻结 P/D 单元、节点、网络、数据许可；资源不足记未执行

4.5.4 大模型部署资源预算与容量门禁

开展 Qwen3.6-27B、DeepSeek V4 Flash 或 Kimi K2.6 测试前必须形成部署容量清单。容量下限按模型权重、运行时开销、KV Cache、激活值和通信缓冲区的总需求计算，并预留不低于 10% 的显存余量；同时检查分片不均、通信工作区和运行峰值。资源不足时记为额外交付“未执行”，不得以投影结果或小模型结果外推。

表 4-9 大模型部署资源预算与容量门禁

对象	精度/工件	容量账单	拓扑	准入条件
Qwen2.5-14B	A1—A4 必测=FP16；W8A8 为同源不可变扩展工件	单卡 HBM 容量、模型权重、KV Cache、激活值和运行时峰值	单卡	先核验 FP16 工件并执行 P0 及 A1—A4；W8A8 资产齐全后单独核验质量和容量，不影响 FP16 结论
Qwen3.6-27B	精确版本号、精度和完整启动参数由本方案配置表固定	权重、KV、激活、通信缓冲区和预留	双卡	按固定配置执行启动与 HBM 验证；峰值保留不低于 10% 余量；不满足时保持禁用

对象	精度/工件	容量账单	拓扑	准入条件
DeepSeek V4 Flash	正式模型工件、KV Cache 精度和完整启动参数由本方案配置表固定	专家、KV、激活、全互联通信缓冲区和预留	单机 8 卡	按固定配置逐卡检查与通信验证；失败时保持禁用，不在测试机调参
Kimi K2.6	正式模型工件、KV Cache 精度和完整启动参数由本方案配置表固定	P/D 权重、KV、通信、网络与预留	多机	固定配置、容量、网络、许可和节点映射齐全后启用；失败时保持禁用

4.5.5 多级多卡部署场景与测试方案

双卡、单机 8 卡和多机测试均属于额外交付，分别服务于两卡切分、MoE/EP 与 all-to-all、跨节点 PD 和超长链路验证。每项只在真实部署上形成结论；若 B0 无法在同一固定拓扑部署，只能形成兼容性或可部署性结论，不得形成 B1/B0 性能提升结论。PD 容量规划按输入、输出、到达率和 SLO 计算，P:D 资源比由固定负载需求和实测单元能力直接推导。

表 4-10 多级多卡部署与测试方案

场景	冻结配置	主要指标	准入与结论边界
Qwen3.6 双卡	与 Qwen2.5 使用相同的 6 类可执行数据集组、负载形状、随机种子和协议；双卡分片方式、最大模型长度、精度和显存参数由本方案配置表一次性固定	各测试单元的容量、TTFT/TPOT、质量、通信开销和 HBM 占用	配置缺失或固定配置无法启动时不执行；独立比较 B0/B1，不跨模型比较
DSV4 高 KV 复用	固定前缀 3840 token、后缀 256 token、输出 256 token、10 组前缀、200 条请求、到达率 1 请求/秒；其余启动参数由本方案配置表固定	命中与驱逐、冷/热请求 TTFT、吞吐、HBM 占用和正确性判定	必须执行缓存关闭/开启对照；固定配置无法运行时保持禁用，不得现场调参

场景	冻结配置	主要指标	准入与结论边界
DSV4 代码	64 个冻结样本；输入不超过 2048 token，输出上限 1024 token	编译 / 单测正确率、TTFT/TPOT、吞吐	固定容器和判定规则；与 Kimi 代码 Agent 分测试配置
Kimi Prefill	采用企业提供并本方案规定的固定配置：张量并行 8，启用专家并行和数据并行，块大小 64，最大序列数 16，KV Cache 为 FP8，最大输入 token 数 16384，采用高吞吐通信后端	输入 token/s、TTFT、队列、网络、KV 传输	原始 YAML、规范化配置和生效值一致后执行；不得现场调参
Kimi Decode	采用企业提供并本方案规定的固定配置：张量并行 1，启用专家并行和数据并行，块大小 64，最大序列数 32，KV Cache 为 FP8，采用低时延通信后端	输出 token/s、TPOT、并发、专家热点	目标 TPOT 不超过 40ms；原始 YAML、规范化配置和生效值必须一致
PD 容量与 P:D	冻结 I_{eff} 、 O 、 λ 、SLO、 μP 、 μD 、CD	$nP = \text{ceil}(\lambda I_{eff} / \mu P)$ ； $nD = \text{ceil}(\lambda O / \mu D)$ ；Little 复核	每个负载的参数由企业实测记录标定；不得跨负载套用

4.6 测试方法与结果判定

4.6.1 环境和配置控制

正式测试前为每个 `profile_id` 生成不可变启动参数合同，覆盖模型工件与服务名、精度和量化、KV Cache 精度与块大小、并行方式、节点与卡映射、P/D 部署、副本数、最大模型长度、显存利用率、序列和批 token 上限、分块预填充、前缀缓存、推测解码、编译与图执行、通信、CPU 绑定、调度、环境变量、种子和请求终止行为。A1-FP16、P0-DIALOGUE-FP16、A2 六单元、A3-32K-FP16 和 A4-MT-FP16 分别形成配置校验值；W8A8 扩展使用独立 `profile` 和 `config_id`。所有性能字段显式填写，不依赖软件默认值。

表附-2 至表附-7 是启动参数和请求参数的唯一来源,评测环境不得搜索、试配或调优。Qwen2.5 单卡统一采用非 P/D 分离服务。A2 六个执行单元分别启动独立 profile; A2-V 只进行模态适用性判定。B0-FP16 与 B1-FP16 除代码提交、镜像身份和角色标识外,规范化服务配置、环境变量、模型工件和客户端合同逐项相同。W8A8 扩展仅允许模型工件、served_model_name 和 quantization 按固定角色合同变化; 其余字段与对应 FP16 profile 一致。两侧保存原始命令、规范化配置、配置校验值和启动生效回执。字段缺失、生效值不一致、图回退或依赖隐式默认值时拒绝测量。固定配置无法运行时保留证据并发布新版本,不自动降级或临时改参。

4.6.2 负载与测量

P0 使用通用问答/多轮数据资产的完整指定分片, 规模不少于 20000 条有效请求, 固定 4.0 请求/秒、并发 32、max_tokens=128, B0/B1 按交替顺序各执行 3 次冷启动生命周期。A2 通用问答/多轮在相同有序请求池上按 0.25、0.5、1、2、3、4、6、8 请求/秒扫描; 工具调用执行不少于 512 个可判定用例, 按 0.25、0.5、1、1.5、2、3、4、6 请求/秒扫描; 推理执行不少于 1000 个可自动判定用例; 结构化输出执行不少于 60 个符合资格规则的 schema; 长上下文从授权文本生成 16 个 8192+512 和 16 个 16384+1024 固定请求。P0 及 A2—A4 的 B0/B1 均使用 compile_mode=vllm_compile 、 enforce_eager=false 、 FULL_DECODE_ONLY 和各 profile 固定 capture sizes。基线不得被强制 eager, B1 不得使用表外单边开关。所有扫描只改变客户端到达率。

4.6.3 重复与统计

每个正式测试单元至少执行 3 次独立完整生命周期（服务冷启动—预热—测量—停止），取预先声明主指标的中位数。一次基准测试中的多请求不计为多次重复。失败、超时、非零错误率和替补运行全部保留；波动异常时可追加两次，但不得替换原集合或选择最好值。每次须绑定相同的解析后配置校验值，并形成重复试验记录和中位数选择记录。

4.6.4 指标计算

表 4-11 统一指标分层、计算口径与适用范围

指标	计算公式	档位、单位与适用范围
请求吞吐	$Q_{req} = N_{ok} / T$	REQUIRED ; request/s; 全部数据集
输入吞吐	$Q_{in} = \Sigma \text{input_tokens} / T$	REQUIRED ; token/s; 全部数据集
输出吞吐	$Q_{out} = \Sigma \text{output_tokens} / T$	REQUIRED ; token/s; 全部数据集
总吞吐	$Q_{total} = \Sigma(\text{input_tokens} + \text{output_tokens}) / T$	REQUIRED ; token/s; 全部数据集
TTFT	$TTFT_i = t_{first,i} - t_{send,i}$; 报告 mean/p95/p99	REQUIRED; ms; 流式服务
TPOT	$TPOT_i = (t_{last,i} - t_{first,i}) / (O_i - 1)$; 报告 mean/p95/p99	REQUIRED ; ms/token; 输出 ≥ 2 token
端到端时延	$E2E_i = t_{end,i} - t_{send,i}$; 报告 mean/p95/p99	REQUIRED; ms; 全部数据集
成功率	$R_{success} = N_{ok} / N_{plan}$	REQUIRED; %; 全部数据集

指标	计算公式	档位、单位与适用范围
正确率/任务得分	$\text{Accuracy} = N_{\text{correct}} / N_{\text{plan}}$; 特殊任务使用冻结官方 scorer	REQUIRED; %或官方分数; 具有 oracle 的数据集
OOM	$N_{\text{OOM}} = \text{OOM 事件数}$	REQUIRED; count; 全部数据集
静默截断率	$R_{\text{trunc}} = N_{\text{silent_truncation}} / N_{\text{plan}}$	REQUIRED; %; 全部数据集
B1/B0 吞吐比	$R_Q = \text{median}(Q_{B1,1..3}) / \text{median}(Q_{B0,1..3})$	REQUIRED; ratio; 全部性能测试
吞吐提升率	$\Delta Q = (R_Q - 1) \times 100\%$	REQUIRED; %; 全部性能测试
时延改善率	$\Delta L = (1 - \text{median}(L_{B1}) / \text{median}(L_{B0})) \times 100\%$	REQUIRED; %; 全部性能测试
跨场景几何平均	$\text{GM} = \exp[(1/K) \sum \ln(R_{Q,k})]$	REQUIRED; ratio; 预声明验收场景
极限百万 token	$C_{\text{raw}} = H \times 10^6 / (3600 \times$	REQUIRED;

指标	计算公式	档位、单位与适用范围
成本	Q_{raw}	货币 /1M token; 价格测试
SLO 百万 token 成本	$C_{\text{slo}} = H \times 10^6 / (3600 \times Q_{\text{slo}})$	REQUIRED; 货币 /1M token; 正式报价
峰值填平率	$\varphi = \text{实际承载容量} / \text{可提供的合规饱和容量}$	REQUIRED; %; 正式报价
报价 (加价率)	$\text{Price}_{1\text{M}} = (C_{\text{slo}} / \varphi) \times (1 + c_{\text{cloud}}) \times (1 + r_{\text{markup}})$	REQUIRED; 货币 /1M token; 正式报价
SLO Goodput	$G_{\text{slo}} = N_{\text{slo}} / T$	ADDITIONAL; request/s; 在线 /rate scan
Cache 命中率	$H_{\text{cache}} = \text{hit_blocks} / \text{queried_blocks}$	ADDITIONAL; %; Prefix/KV/ 复用场景

指标	计算公式	档位、单位与适用范围
HBM 峰值	$\text{HBM_peak} = \max_t \text{HBM_used}(t)$	ADDITIONAL; GiB; 全部数据集
NPU 平均利用率	$\text{U_NPU} = (1/T) \int \text{U_NPU}(t) dt$	ADDITIONAL; %; 全部数据集
MFU	$\text{MFU} = \text{TFLOPS_effective} / \text{TFLOPS_peak}$	ADDITIONAL; %; A1 固定形状
报价 (会计毛利率)	$\text{Price_1M} = (\text{C_slo} / \varphi) \times (1 + \text{c_cloud}) / (1 - \text{m_gross})$	ADDITIONAL; 货币/1M token; 正式报价
三轮变异系数	$\text{CV} = \text{std}(x_1, x_2, x_3) / \text{mean}(x_1, x_2, x_3)$	ADDITIONAL; ratio; 稳定性诊断
平均功耗	$\text{P_avg} = (1/T) \int \text{P}(t) dt$	ADDITIONAL; W; 能耗诊断
每百万 token 能耗	$\text{E_1M} = \int \text{P}(t) dt / (\text{N_token} / 10^6)$	ADDITIONAL; kWh/1M

指标	计算公式	档位、单位与适用范围
		token； 能耗 诊断
Jain 公平指数	$J = (\sum x_j)^2 / [m \times \sum (x_j^2)]$	ADDITIONAL； 0–1； A4 多租户

4.6.5 A1 有效算力专项规则

A1 固定主形状为输入 4096 token、批量 8，辅助形状为输入 1024 token、批量 32 和输入 8192 token、批量 4；输出长度 1 token，采用闭环负载，预热 10 轮、测量 30 轮。服务配置为 FP16、张量并行 1、流水并行 1、数据并行 1、最大模型长度 32768、显存利用率 0.85、关闭前缀缓存和分块预填充、最大序列数 32、单批最大 token 数 32768，并忽略终止符。910B2 FP16 峰值分母按本方案规定的 ascend-dmi 三次测量中位数确定；有效 FLOPs 按 effective_compute_spec v1 计算，并要求与 msprof 校准误差不超过 3%。校准只核验计量口径，不得据此更换主形状或调整启动参数。

表 4-12 A1 有效算力计算与防选择性规则

控制项	固定规则	必备证据
有效算量	effective_compute_spec.json 按模型版本和精度给出完整模型前向算量公式，B0/B1 共用一份规范	版本化规范、公式推导、模型配置/权重哈希和复算脚本
Padding 与 MoE 计数	分子不计入 masked/padded token 和未路由专家的无效算量；实际物理执行算量另行报告	有效/物理 token 数、专家路由日志、硬件计数器与差异说明
理论峰值分母	固定精确芯片型号、数值精度和稠密/稀疏模式的官方峰值；仅在本方案规定的稀疏模式真实执行时可用稀疏峰值	厂商正式规格文件、设备识别、精度与稀疏执行回执

控制项	固定规则	必备证据
形状冻结	预先固定 1 个主形状和 2 个辅助形状；主形状在看到正式结果前指定；禁止 best-of、扫描后择优或替换主形状	版本化形状记录、预试验记录、正式测试启动时间和全部形状结果
时间边界	预热后对完整模型前向执行同步墙钟计时，包含 kernel launch、必要同步和计算通信，排除 tokenizer 和 HTTP 网络	端到端前向时戳、显式同步代码路径、Profiler 时间线和原始计时记录
重复与复核	至少 3 次独立生命周期测量，按本方案 5.3 选取中位数；算量规范、输入和原始证据均留存哈希	三次/五次原始结果、规范哈希、roofline/计数器交叉验证和第三方复算记录

4.6.6 A4 全系统单位 token 成本规则

A4 使用 A4-MT-FP16-PC 配置，B0 与 B1 均启用前缀缓存和 FULL_DECODE_ONLY，五租户分别引用已冻结的通用问答/多轮、工具/Agent、推理、结构化输出和代码数据集组。先以 32、64、96、128、192、256、384 输出 token/秒固定点扫描 B0-FP16 混合容量，每点 600 秒、点间排空 60 秒；正式负载取三次扫描中位最大合规速率的 70%。各租户投递输出 token 份额 20%，每租户并发上限 4，全局 16，预热 5 分钟、测量 30 分钟。B1-FP16 每百万成功输出 token 全生命周期成本较 B0-FP16 降低不低于 30%；Jain 公平性不低于 0.90，份额相对 20%偏差不超过 10%，各租户 p99 TTFT 和 TPOT 不超过隔离 B0 同负载的 1.25 倍；样本不足 1000 时 0 失败，单卡平均利用率不低于 60%。W8A8 扩展结果单列，不替代 FP16 判定。

表 4-13 A4 成本与利用率核算要求

核算项	强制规则	结论要求
主指标	FP16 必测线的全系统每百万成功输出 token 成本；B0-FP16 与 B1-FP16 使用相同资源边界、价格时点、摊销周期、负载和 SLO	B1-FP16 较 B0-FP16 降低 $\geq 30\%$ ；W8A8 扩展结果单列
成本分子	纳入 NPU、CPU/内存主机、节点间网络、存储/KV 服务、能耗、付费软件/服务、预留空闲及失败/超时/重试请求消耗	任一实质成本分项缺失、以零代替或无法复核时，A4 记为不具备判定条件

核算项	强制规则	结论要求
成本分母	仅计入完成质量、协议和 SLO 检查的成功输出 token; 输入 token 及失败输出不得扩大分母	保留成功/失败请求、输入/输出 token 和重试链路的完整分母
价格与分摊	冻结同一价格时点、计费币种、税费口径、使用率假设、购置/租用模式和折旧或摊销规则	价格依据、版本化全系统成本清单和可重算表须同时交付
设备利用率	固定厂商计数器及采样频率; A4 单卡配置同时报告整机平均、单卡平均和时间窗口 p10/p50/p90	A4 单卡平均利用率不低于 60%; 单卡即该测试配置的集群平均, 不另设 70% 门槛; 不得用短时峰值掩盖整体利用率
补充指标	可另行报告 NPU-only 成本、NPU 卡时和每 token 能耗, 但必须与全系统主指标同期、同负载	补充指标仅用于归因, 不得单独支持 A4 通过结论

4.6.7 结果判定与复测

任务书阈值、工程健康线和对外提升数字必须分开。A1—A4 仅按本方案合同阈值判定; 九项公共负载的吞吐回退不超过 1%、TTFT 恶化不超过 10%、TBT 恶化不超过 5%, 仅用于夜间工程回归, 不属于验收目标。未经同规格 B0/B1 正式证据, 不得发布提升结论。额外交付结果不影响 A1—A4 结论。

4.6.8 研发阶段正确性门禁与专用性能测试

持续集成与持续交付只执行静态校验、单元测试、构建、请求合同校验和签名结果发布门禁, 不直接占用加速卡。正式性能请求由持续集成系统提交至独立评测服务, 经鉴权、幂等校验、排队、独占资源锁和预检后运行; 产物保存至不可变存储并由服务器签名。只有验签通过的证据包可进入结果快照、项目网站和验收报告。普通代码变更不运行正式性能测试; 版本发布、里程碑和正式验收必须完成 Qwen2.5 的 A1—A4。

表 4-14 CI/CD 最小正确性门禁

门禁	触发范围	执行内容	放行规则
普通 PR	全部变更	托管式持续集成环境静态检查、单测、构建、合同/Schema/哈希校验；不占 NPU	全部通过；不得用自托管执行器直跑性能
评测请求门禁	性能评测标签或发布请求	鉴权签名、幂等、测试目标登记表、资源/磁盘/模型/数据预检、队列与独占锁	合同不完整或显式证据冲突即拒绝；资源占用保持等待
结果门禁	独立评测服务执行完成	校验运行环境来源记录、原始数据、重复试验记录、规定的中位数选择记录、签名和校验清单	只有验签通过的证据包可进入结果快照、项目网站以及合入或发布结论

持续集成使用的最小正确性请求集应保持规模小、内容固定、可重复，并具有明确判定规则；按变更影响范围选择必要用例。该检查不执行并发爬坡、到达率搜索、稳态测量、洪峰注入、跨次统计或基线性能比较，也不以 TTFT、TPOT、吞吐、SLO 合规吞吐、显存高水位和设备利用率作为放行阈值。即使采集上述字段，也仅用于故障诊断，不形成性能结论。小模型和小样本仅验证路径正确性，不替代正式模型、正式数据和正式验收配置。

表 4-15 专用测试机性能测试分级与触发条件

级别	触发条件	执行范围	执行要求	结论用途
定向性能复测	性能关键路径变化	仅受影响的已冻结测试目标/测试单元	独立评测服务独占资源；至少 3 次生命周期；完整保留失败记录	判断回归/收益
必须交付全量	版本发布、里程碑或正式验收	Qwen2.5 的 A1—A4；A2 包含 5 个测试单元	各项运行超时上限按表附-6 和表附-7 执行并写入配置清单；未取得验签结果不得放行	形成任务书结论

级别	触发条件	执行范围	执行要求	结论用途
额外交付	模型、资源、数据和资格化回执齐全	Qwen3.6、DSV4、Kimi 对应测试配置	满足准入条件后启用；失败不阻塞必须交付	亮点与能力边界
夜间工程回归健康线	主分支定时任务	九项公共工程负载	只做工程趋势；失败阻止结果快照和项目网站晋升	不进入项目验收

独立评测服务统一管理评测卡，持续集成执行器不得直连设备或直接执行性能测试，也不得终止或重启其他任务。评测队列应支持幂等键、优先级与配额、取消与超时、心跳、审计日志、并发锁、磁盘/模型/数据预检、维护模式和紧急人工禁用。资源占用时保持等待状态且不得放行；失败、取消、超时或证据缺失均不通过。基础设施故障须保留原执行记录，并在资源恢复后完整重跑。

普通代码变更通过持续集成的最小正确性检查后可进入代码评审。性能关键路径变更只复测受影响的固定测试配置；版本发布、里程碑和正式验收执行相应完整矩阵。人工操作仅用于选择受影响的固定测试配置，不替代固定配置执行、阈值判定和证据留存。

CI/CD 与专用测试机的结论应严格隔离：CI/CD 只给出“正确性检查通过/不通过/未执行”的状态；专用测试机按第 2—5 章给出性能、稳定性、扩展效率和验收结论。任何 CI/CD 运行中观察到的性能数值均不得写入正式验收结果，也不得替代专用测试机复测。

4.7 本课题测试交付与第三方评测

4.7.1 本课题交付材料

表 4-16 本课题正式测试与验收交付材料

材料	主要内容	要求
测试方案正式文本	四模型/九负载绑定、A1—A4 合同、阈值、32K 口径和第三方范围	本方案与同版本测试目标登记表配套执行

材料	主要内容	要求
固定测试资产	FP16/W8A8 模型 manifest、量化配置与质量回执、数据 manifest、oracle/parser、绝对 SLO、有效算量规范和成本规则	由课题组形成版本化测试资产并随测试包交付；第三方逐项核验清单与本方案一致后执行
运行绑定包	B1 exact refs、两侧 OCI 摘要、配置校验值、实际 CLI、环境与设备回执、到达序列和签名身份	正式执行前形成；字段完整且校验通过后启用对应正式测试目标
原始证据	原始请求与聚合结果、服务端和测试端日志、启动日志、来源记录、环境记录、输入记录、重复试验和失败记录	保留完整分母、时间戳、配置校验值和文件校验值；不得删除失败记录
验签通过的证据包	规定的中位数选择记录、签名、公钥 ID、校验清单	验签通过后才能进入报告/结果快照和项目网站
正式报告	A1—A4 逐项方法、结果、偏差、复测、结论	任务书结论单独成章；健康线和宣传数字隔离
额外交付附录	Qwen3.6、DSV4、Kimi 实际完成项	未执行不写成能力；不得替代必交

4.7.2 第三方执行流程

第三方按表附-10 至表附-19 执行：接收并校验 V4.6 测试包、资源隔离、模型和数据资产矩阵核验、B0/B1 镜像与源码核验、配置生成与逐字段比较、连通性检查、P0 全量对照、A1、A2 六个执行单元及 A2-V 适用性检查、A3、A4、结果复算、证据包签名和报告签发。连通性检查不进入统计。不得搜索参数、比较参数组合、根据结果更换 profile、dataset_id、test_tier 或 data_profile_id，也不得删除失败或用其他精度替代必测线。

5 测试风险分析

正式测试开始后，测试类别、测试配置、芯片、模型、精度、拓扑、基准软件、数据、负载、SLO、启动参数合同、有效算量规范、部署容量清单或全系统成本口径发生变化时，应停止受影响测试，发布新版本方案并完整复测。任何性能相关启动参数变化均产生新的配置标识和参数校验值；旧结果不得与新配置合并。可能改变 A1—A4 或能力结论的偏差不得豁免。

6 测试工作安排

6.1 测试进度

表 6-1 测试工作阶段安排

阶段	任务书目标	测试工作	主要产物
2026 年 6 月—11 月	单机单卡原型可测可比；单芯片有效算力达到理论峰值 50%以上	形成基准配置、指标口径、基线脚本和初始数据；完成单芯片阶段测试	调研报告、指标/脚本说明、基线数据、架构报告和单机单卡原型
2026 年 12 月—2027 年 5 月	单一业务场景单位 token 成本阶段性降低 10%以上	开展单芯片优化回归和企业业务场景成本测试	单芯片优化阶段报告、量化/稀疏联动工具原型和回归证据
2027 年 6 月—11 月	KV 池化/分层原型；16K 长上下文稳定验证	完成 KV 复用和长上下文阶段测试，固化可复测脚本	KV 池化/分层原型、长上下文测试大纲和脚本
2027 年 12 月—2028 年 5 月	多租户压测闭环；第三方材料准备	完成多租户、典型场景吞吐/时延和成本预验收	多租户实验记录、第三方测试材料和问题整改记录
2028 年 6 月—11 月	本项目四项最终指标及第三方验收	执行 A1-A4 正式测试、复测和示范部署验证	可发布软件栈、第三方测试报告、最终科技报告/自评价、示范部署案例与运维指南/技术规范

6.2 人员与职责

表 6-2 测试职责

角色	职责	配置与结论管理
甲方	发布测试方案与任务书口径; 接收正式测试报告	以本方案明确 14B 等效模型、32K 计算方式、SLO、算力和成本口径; 接收按本方案形成的验收材料
华中科技大学课题组	维护测试资产、固定配置、数据、判定程序和版本库	发布模型/数据 manifest、oracle/parser、测试目标登记表和配置版本
派欧云计算(上海)有限公司	提供授权国产芯片环境、企业数据和业务场景, 保障部署运行	登记数据用途、资源条件、资产价格与能耗依据
第三方测试机构	按本方案与 config version 独立执行、复算和出具报告; 依照表附-10 至表附-19 逐步留痕	核验 FP16/W8A8 工件、profile 校验值和签名证据包, 形成 A1—A4 正式结论; 不改变固定参数、不替换工件
数据与安全负责人	执行授权、脱敏、访问控制、留存和删除管理	确保企业数据不超范围使用和披露

附：正式测试配置冻结表

本附表与正文具有同等约束力，是 Qwen2.5-14B 单卡 P0 及 A1—A4 生成启动命令、客户端请求和证据包的唯一参数来源。P0 及 A1—A4 必测线固定为 B0-FP16 与 B1-FP16；W8A8 扩展使用独立 profile，不影响必测线结论。提交 SHA、镜像摘要、物理设备号、comparison_id、config_id、实际命令和运行回执纳入证据包。任何固定字段缺失、出现表外差别、图执行未生效或生效值不符，均按 fail-closed 拒绝测量。

表附-1 版本角色与比较关系

字段	固定值	执行约束
baseline_role	B0	upstream vLLM 0.18 基准； core=bcf2be96120005e9aea171927f85055a6a5c0cf6； plugin=e18643f8a4d5bd9990727654318ad069ea0b56e2
candidate_role	B1	正式优化验收版本； core=1a06c55468966de8ef471ecb7612c199e15a153a； plugin=ac2b94f1536090e2cd0d6c2f8bc8087e336193d5
comparison	B0_vs_B1	必测比较为 B0-FP16 对 B1-FP16。P0 及 A2—A4 使用相同模型 FP16 工件、请求和服务配置。W8A8 扩展包括 B1-W8A8 相对 B1-FP16 的量化增量、B0 原生兼容时的同量化对照，以及 B1-W8A8 相对 B0-FP16 的端到端系统结果；三类结果分别命名、分别解释，不相互替代。
禁止角色	第三档编号、关闭优化版本、诊断基线	不得进入 registry、CI、证据包、报告或验收结论

表附-2 A1—A4 共同服务端参数

参数	固定值	生效校验
model_family	Qwen2.5-14B-Instruct	验收前绑定 exact model revision 与完整权重清单
served_model_name	A1/P0/A2—A4 FP16 均使用 qwen2.5-14b-instruct-fp16；W8A8 扩展使用 qwen2.5-14b-instruct-w8a8	固定 API 逻辑名，不以本地路径作服务名
api_server_count / protocol	1 / openai	A1 使用 /v1/completions；A2/A3/A4 使用 /v1/chat/completions

参数	固定值	生效校验
listen address / port	host=127.0.0.1; port=运行时分配	端口进入 receipt 但不构成性能分组维度
frontend workers / logs	uvicorn_workers=1; log_level=INFO; access_log=false	请求原文由 client 证据保存, 禁用逐请求访问日志以固定开销
service timeouts	startup_health_timeout=900s ; health_interval=5s ; graceful_shutdown_timeout=120s	超时即保留失败并终止本生命周期
dtype / quantization	必测 profile=float16/null; W8A8 扩展 =float16/ascend	A1=float16/null; A2—A4=float16/ascend; 不得继承默认值
kv_cache_dtype	requested=auto; effective=torch.float16	请求值与实际值均入 receipt, 实际非 FP16 即拒绝
block_size	128	启动 receipt 必须显示 128
TP / PP / DP / EP / DCP	1 / 1 / 1 / 1 / 1	B0/B1 逐项一致
serving_mode	unified	pd_disaggregation=false
replicas	server=1 ; prefill_only=0 ; decode_only=0	pd_ratio=not_applicable
speculative	false; model=null; tokens=0	Qwen2.5 A1—A4 显式关闭; Qwen3.6 额外交付按表 4-1 独立启用 MTP
scheduling_policy	fcfs	禁止执行端改调度策略
distributed_executor_backend	mp	单卡固定
dcp_comm_backend	ag_rs	即使 DCP=1 也显式记账
disable_custom_all_reduce	true	单卡固定
cpu_binding_policy	topo_affinity	OMP_NUM_THREADS=1; 根据所分配 NPU 的 NUMA 节点生成 CPU 核表并写入 startup receipt; 禁止扫描线程数或跨 NUMA 手工改核
compile_mode	A1 : B0/B1=none ; A2—A4 : B0/B1=vllm_compile	两侧显式相同; 不得采用软件默认值
enforce_eager	A1: B0/B1=true; A2—A4: B0/B1=false	A2—A4 任一侧不得自动回退 eager
cuda_graph	A1: B0/B1 mode=none、warmups=1, 实际图捕获次数必须为 0; A2—A4: B0/B1 mode=FULL_DECODE_ONLY、 warmups=1	两侧 capture sizes 按表附-3 相同固定; 实际捕获、命中和回退进入证据包
tokenizer_mode / trust_remote_code	auto / false	实际 tokenizer revision 由模型清单绑定

参数	固定值	生效校验
load_format	auto; effective=safetensors	effective 非 safetensors 即拒绝
engine_seed	0	服务端固定种子
LoRA / prompt adapter	false / false	正式验收禁用
KV offload / swap / CPU offload	false / 0 GiB / 0 GiB	禁止隐式主机侧换出

表附-3 工作负载专属服务端配置

profile_id	固定覆盖值	执行说明
A1-FP16	artifact=FP16; dtype=float16; quantization=null; max_model_len=32768 ; gm=0.85 ; max_num_seqs=32 ; max_num_batched_tokens=32768 ; prefix=false ; chunked=false ; speculative=false ; enforce_eager=true ; cudagraph=None ; cudagraph_num_of_warmups=1; 实际图捕获次数=0; endpoint=/v1/completions	主形状 4096×8→1; 辅助 1024×32→1、8192×4→1; ignore_eos=true 为请求字段
A2-DIALOGUE-<PRECISION>-PC	PRECISION=FP16 或 W8A8 ; gm=0.85 ; maxseq=32 ; maxbatched=16384 ; prefix=true ; chunked=true; speculative=false; 共同图配置; capture_sizes=[1,2,4,8,16,32] ; endpoint=/v1/chat/completions	DIALOGUE-PUBLIC 完整指定分片; P0 固定 4.0 RPS 全量执行; 容量阶段使用相同有序请求池; 保存 data_profile_id、prefix cache 及图捕获/命中/回退证据
A2-TOOL-<PRECISION>-PC	PRECISION=FP16 或 W8A8 ; gm=0.85 ; maxseq=16 ; maxbatched=8192 ; prefix=true ; chunked=true; speculative=false; 共同图配置; capture_sizes=[1,2,4,8,16]; auto_tool_choice=true	真实 tools、tool_choice=auto、parallel_tool_calls=true; 两侧保存工具解析、协议结束及图执行证据
A2-REASON-<PRECISION>	PRECISION=FP16 或 W8A8 ; gm=0.85 ; maxseq=16 ; maxbatched=8192 ; prefix=false ; chunked=true; speculative=false; 共同图配置; capture_sizes=[1,2,4,8,16]	长输出推理; 固定答案抽取器; 两侧保存图执行与质量证据
A2-STRUCT-<PRECISION>	PRECISION=FP16 或 W8A8 ; gm=0.85 ; maxseq=16 ; maxbatched=8192 ; prefix=false ; chunked=true; speculative=false; 共同图配置; capture_sizes=[1,2,4,8,16]; backend=xgrammar	逐 case 发送 JSON Schema ; 两侧保存 Schema、wire request、解析结果及图执行证据
A2-LONG-<PRECISION>	PRECISION=FP16 或 W8A8; gm=0.85; maxseq=4; maxbatched=16384; prefix=false; chunked=true; speculative=false ; 共同图配置 ; capture_sizes=[1,2,4]	16×8192+512、16×16384+1024; 分别报告 Prefill TTFT、Decode TPOT、容量和两侧图命中
A2-CODE-<PRECISION>	PRECISION=FP16 或 W8A8; gm=0.85 ; maxseq=8 ; maxbatched=8192 ; prefix=false; chunked=true; speculative=false; 共同图配	CODE-GROUP 完整冻结请求; closed-loop 并发 8; 使用冻结编译/单测/官方

profile_id	固定覆盖值	执行说明
	置； capture_sizes=[1,2,4,8]； endpoint=/v1/chat/completions	scorer； 保存逐 例代码、编译、 测试、时延、 token 及图执行 证据
A3-32K-<PRECISION>	PRECISION=FP16 或 W8A8; gmu=0.85; maxseq=1; maxbatched=16384; prefix=false; chunked=true; speculative=false; 共同图配置; capture_sizes=[1]	总 上 下 文 32768=30720+2048 ； ignore_eos=true; 两侧 30 分钟内不得图回退或新增 捕获
A4-MT-<PRECISION>-PC	PRECISION=FP16 或 W8A8 ； gmu=0.85 ； maxseq=16 ； maxbatched=16384 ； prefix=true ； chunked=true; speculative=false; 共同图配置; capture_sizes=[1,2,4,8,16]; auto_tool_choice=true	五租户共享单一服务；工 具租户发送 tools; 代码租 户使用冻结 scorer; 两侧 保存逐租户图命中、回退、 SLO、质量和公平性证据
共同拓扑	TP=1; PP=1; DP=1; EP=1; DCP=1; unified; pd_disaggregation=false ； server_replicas=1 ； prefill_only=0; decode_only=0	A1—A4 均为单张 910B2; 不得由 adapter 推断
工具与模板	tool_call_parser=hermes; tool_parser_plugin=null; reasoning_parser=null; chat_template=固定 tokenizer 内 置 模 板 ； content_format=string ； trust_request_chat_template=false ； template_kwargs={}	B0/B1 使用相同模板字节 和解析器； 保存模板 SHA-256 及渲染后 ordered token IDs/hash
结构化输出	structured_outputs_backend=xgrammar ； disable_any_whitespace=false ； disable_additional_properties=false	禁止 backend=auto; B0/B1 实际生效后端必须一致

表附-4 环境变量与设备绑定

变量	固定值	约束
VLLM_TARGET_DEVICE	npu	B0/B1 相同
VLLM_USE_V1	1	B0/B1 相同
VLLM_WORKER_MULTIPROC_METHOD	spawn	B0/B1 相同
PYTHONHASHSEED	0	B0/B1 相同
TOKENIZERS_PARALLELISM	false	B0/B1 相同

变量	固定值	约束
HF_HUB_OFFLINE / TRANSFORMERS_OFFLINE / HF_DATASETS_OFFLINE	1 / 1 / 1	禁止正式测试联网取模型或数据
HCCL_CONNECT_TIMEOUT	120	单位秒
ASCEND_VISIBLE_DEVICES	独立评测系统分配的独占单卡 ID	物理卡号进入每次签名 receipt，不作为趋势分组维度
OMP_NUM_THREADS / CPU 核表	1 / 根据 NPU NUMA 拓扑分配	CPU 核表进入运行回执；不得扫描线程数或跨 NUMA 手工改核
PYTORCH_NPU_ALLOC_CONF	expandable_segments:True	B0/B1 相同；启动回执记录
TASK_QUEUE_ENABLE	1	B0/B1 相同；不得在运行中改变
其他执行变量	禁止；不得进入正式测量	额外影响性能的环境变量一律拒绝

表附-5 统一客户端采样与重复规则

字段	固定值	约束
temperature / top_p / top_k / min_p	0.0 / 1.0 / -1 / 0.0	所有 cell 一致
presence / frequency / repetition penalty	0.0 / 0.0 / 1.0	所有 cell 一致
n / best_of / beam_search	1 / 1 / false	禁止多结果择优；best_of 为 normalized-only 语义，不向不支持该字段的 HTTP endpoint 发送
stop / stop_token_ids	[] / []	EOS 行为由各 profile 的 ignore_eos 决定
ignore_eos (请求字段)	A1=true ; A2=false ; A3=true ; A4=false	写入每个 canonical request；严禁渲染成 serve CLI 参数
max_tokens	按各 cell 的→值或 output cap 逐请求 显式填写	A1=1；A3=2048；A2/A4 按 case 合同
min_tokens / echo	0 / false	所有请求显式填写
A1 Completion 日志概率字段	logprobs=null；不发送 top_logprobs； prompt_logprobs=null	按/v1/completions 字段类型生成 wire request
A2/A3/A4 Chat 日志概率字段	logprobs=false；top_logprobs=0； prompt_logprobs=null	按/v1/chat/completions 字段类型生成 wire request
parallel_tool_calls	tool_calling 及 A4 tool 租户=true；其 他请求 not_applicable 且不发送 tools/tool_choice/parallel_tool_calls	不依赖 v0.18 默认值；multi/parallel case 必须显式为 true
detokenize / skip_special_tokens / spaces_between_special_tokens	true / true / true	detokenize 为 normalized client/response 语义，不向不支持该字段的 HTTP endpoint 发送

字段	固定值	约束
add_special_tokens / truncate_prompt_tokens	true / null	禁止静默截断；长度不合规直接失败
add_generation_prompt / continue_final_message	true / false	渲染后 ordered token IDs 及 SHA-256 进入证据
request identity	user 与 request_id 由 config_hash、 cell_id、repeat、sequence_no 确定性 生成	同一 B0/B1 请求 ID 及顺序一致；规则进入 client adapter 版本
stream_options	{"include_usage":true}	所有 Chat 请求固定发送；A1 /v1/completions 按同一流式计时规则记录首 token 与后续 token
client_seed	0	B0/B1 使用字节一致的请求及 arrival 序列
streaming	true	所有 Chat 请求采用流式响应；TTFT 取服务 端首个有效输出 token 时间戳，TPOT 按后 续 token 间隔计算；B0/B1 使用同一计时实 现
repeats	3 个独立完整生命周期	冷启动—预热—测量—停止；异常仅可追加 2 次，不替换原结果
结果选择	每个阶段按预声明 primary_metric 取 3 次中位数	容量扫描、共同负载、A3 和 A4 分别选择； 失败、超时、错误和静默截断全部保留
响应有效性	HTTP/协议错误、error 字段、超时、 输出 token 数与 max_tokens/EOS 状 态、截断标志逐请求记录	无法解释的短输出或 token 身份不一致按 silent truncation 失败
wire request 约束	adapter 仅发送目标 endpoint 支持的 字段，并保存 rendered HTTP body 及 SHA-256	normalized-only 字段不得作为 extra 静默发 送或依赖服务端忽略

表附-6 A1 与 A2 固定客户端合同

单元	数据/形状与负载	时长、上限与超时
A1-FP16	closed-loop; 主 4096×batch8→1; 辅助 1024×32→1、8192×4→1	warmup=10 轮 ; measure=30 轮 ; per_request_timeout=300s ; lifecycle_timeout=1800s; primary=主形状 MFU
A2 共同执行法	每个 cell 独立启动对应 profile; Poisson seed=0; rate 固定升序; 按签名 ordered case list 循环, 不随机重抽; 同一 rate 序列供 B0/B1 复用	预热 5min ; 每 rate 测量 600s ; rate 间 drain/cooldown=60s; request_cap=ceil(rate×600); 每个容量阶段重复 3 个完整生命周期
dialogue_multiturn	profile=A2-DIALOGUE-FP16-PC ; data_profile=DIALOGUE-PUBLIC; 完整指定分片不少于 20000 条 ; P0 固定 4.0 RPS 、 max_concurrency=32 、 max_tokens=128; A2 容量 rates=0.25/0.5/1/2/3/4/6/8	P0 每角色 3 生命周期, 执行顺序 B0-1/B1-1/B0-2/B1-2/B0-3/B1-3 ; requests 与 schedules SHA-256 由正式执行包生成并写入 data_profile_id; 容量阶段按 B0 最大合规点×0.70 生成共同负载
tool_calling	profile=A2-TOOL-FP16-PC ; data_profile=TOOL-PUBLIC; 不少于 512 个用例并覆盖单工具、多工具 / 并行和多轮 ; rates=0.25/0.5/1/1.5/2/3/4/6; max_concurrency=16	B0 三次容量中位最大合规点×0.70 生成共同负载; B0/B1 共同负载各 3 生命周期 ; capacity_timeout=7200s; common_timeout=1800s; per_request_timeout=300s; primary 同 dialogue 并设工具质量门槛
reasoning	profile=A2-REASON-FP16 ; data_profile=REASON-PUBLIC; 不少于 1000 个可自动判定用例 ; output_cap=512 ; rates=0.25/0.5/1/1.5/2/3/4; max_concurrency=16	per_request_timeout=600s ; capacity_timeout=6300s; 重复 3 生命周期; primary=质量正确率和错误率, 性能完整报告
structured_output	profile=A2-STRUCT-FP16 ; data_profile=STRUCT-PUBLIC; 不少于 60 个合格 schema; OpenAI JSON Schema; output_cap=512; rates=0.25/0.5/1/1.5/2/3/4; max_concurrency=16	per_request_timeout=600s ; capacity_timeout=6300s ; 重复 3 生命周期 ; primary=Schema 合法率及任务成功率, 性能完整报告
long_context_capacity	profile=A2-LONG-FP16 ; data_profile=LONG-PUBLIC; 确定性生成 32 例: 16×8192+512 、 16×16384+1024 ; rates=0.05/0.1/0.2/0.4; max_concurrency=4	per_request_timeout=1800s ; capacity_timeout=7200s; 重复 3 生命周期; 仅报告容量边界、错误率、HBM 和 KV 使用量
code	profile=A2-CODE-FP16 ; data_profile=CODE-GROUP; InstructCoder 、 LiveCodeBench、HumanEval、 MBPP、SyFi 分别使用完整冻结 split; PAIO-CODE-EVAL 为扩	warmup=5min; 每个数据集完整执行 ; per_request_timeout=1800s; lifecycle_timeout=7200s; 重复 3 生命周期; primary=官方任务得分和成功率, 吞吐、TTFT、

单元	数据/形状与负载	时长、上限与超时
	展引用； closed-loop ； max_concurrency=8; 不得截断 官方题目或测试	TPOT、E2E 完整报告

表附-7 A3 与 A4 固定客户端合同

任务	固定执行值	判定边界
A3	profile=A3-32K-FP16 ； data_profile=LONG-PUBLIC ； total_context_tokens=32768 ； input_tokens=30720; max_tokens=2048; ignore_eos=true; closed-loop; concurrency=1; seed=0; warmup=5min ； measure=30min ； 6×5min 窗口 ； max_requests=64 ； min_completed=24 ； per_request_timeout=1800s; lifecycle_timeout=3600s; repeats=3	primary= 窗 口 吞 吐 CV 、 TTFT/TPOT 漂 移及 0 失败; 输 入 token 数 以 chat template 渲 染 后 的 token IDs 计; 不得静 默截断、使用随 机 token 或在运 行 后 更 换 LONG-PUBLIC 内容
A4	profile=A4-MT-FP16-PC ； tenants=DIALOGUE-GROUP/TOOL-GROUP/REASON-GROUP/STRUCT-GROUP/CODE-GROUP; offered output-token share 各 20%; B0 容量点=32/64/96/128/192/256/384 output token/s, 每点 600s、 间隔 60s 、 重复 3 次; 正式 global_load=0.70×B0 中位最大合规速率; Poisson seed=0 ； per_tenant_concurrency=4; global=16; warmup=5min; measure=30min; repeats=3	primary= 每 百 万 成 功 输 出 token 全生命周 期成本; 设备和 主机按资产原 值÷21600 小时 计, 电费按 0.60 元/kWh 及实测 功耗计, 人工不 计入机器运行 成本并单列; 各 比较关系使用 同一价格时点 和分摊规则

表附-8 正式测试固定值与运行绑定项

固定值或绑定规则	生效与
cf2be96120005e9aea171927f85055a6a5c0cf6 , plugin=e18643f8a4d5bd9990727654318ad069ea0b56e2 , 本地 image 761f4fad8beeb230e42b58af5a145ea03e0759411c8983486ce2c97ffec0c8d 。 B1 core=1a06c55468966de8ef471ecb7612c199e15a153a , f1536090e2cd0d6c2f8bc8087e336193d5 , 本地 image 437fbd78886648d5c80bae4bdf0fc9ec8fbda8eb7c593993098acd81ac34e2。第三方签发使用 OCI repo digest 或离线 OCI 内容摘要。	B0 提交不匹配即拒绝摘要和 clean-overlay 配置版本并纳入执行行
5-14B-Instruct ; revision=cf98f3b3bbb457ad9e2bb7baf9a0125b6b88caa8 ; tokenizer.json 82117ea329cdf097041132f6d735924b697924d6f6fc3945713e96ce87539 ; FP16 manifest 54be4fc6edc59295d260c735c4e3ef8ba5841a15376ab7c69aaf10704。B0/B1 必测线使用同一 FP16 工件；W8A8 扩展另行绑定完整	测试包同时提供 I weight/tokenizer SHA- 清单必须记录 quantiz 置、源工件 revision 和 方只核验并使用交付 化。
件由固定 FP16 工件生成；必须同时保存量化配置、源 revision 和每个分片 hash，并使用与 FP16 必测线相同的 TOOL、REASON、 ODE 和 LONG 数据集组执行质量对照。	推理、工具、结构化、 分相对同源 FP16 下 Schema 合法率 100%； ≥95%；不合格时不得拒 必测线仍按固定合同
件-7 固定共同外部合同和规范化配置；comparison_id=SHA-256(JCS 角色化比较合同)；B0/B1 config_id 分别对代码/镜像身份与同一 A-256	adapter 生成两侧实际 receipt；comparison_id 工件或生效值不符即拒
固定 eager、cudagraph=none、warmups=1，实际图捕获次数必须为 0。A2—A4 的 B0/B1 均固定 compile=vllm_compile、 =false、cudagraph=FULL_DECODE_ONLY，并使用表附-3 相同 capture sizes 和 warmups=1	保存两侧完整执行模 获、发生回退、使用 量期新增捕获时拒绝
910B2；卡数=1；容器代际=Ascend v0.23；CANN=9.1；其余环境变量见表附-4。	driver、firmware、to 和物理 NPU assignme 证据包；不匹配或缺
OMPUTE、DIALOGUE、TOOL、REASON、STRUCT、CODE、VISION、LONG-KV 和 A4-TENANT 组绑定；同一物理 dataset_id 跨 profile 通过 manifest 引用。	每个引用记录 data test_tier、contract_rol 源、许可、revision、 日志、全部 case_id 和 根据 B0/B1 结果筛选
n-hust-poisson-v1；seed=0；每个 rate 按表附-6 生成完整到达时间序列；clock=monotonic。	arrival generator 和 cli revision/hash；ordered SHA-256 进入请求清 列。
时本地 FIFO 等待；保留 nominal timestamp 并记录 send lag；不丢弃、不重排、不突发追赶；超过 cell timeout 即失败。	规则、nominal timesta send lag 全部进入证据
tool name/arguments oracle；reasoning 使用固定答案抽取器；structured 使用固定 schema dialect 校验器；code 使用冻结官方 scorer、 ；dialogue 检查协议成功和多轮连续性；long 检查目标事实、无截断及输出 token 数。	oracle/parser 与 client 定 exact revision/hash； 一 64 例直接记录，不

固定值或绑定规则	生效与
与 A4 记录 prefix_cache_queries/hits; P0 及 A2—A4 记录 graph_capture_count、graph_hit_count、graph_fallback_count、capture_sizes ne; W8A8 扩展记录量化生效值	规定机制未生效、计数 图回退或生效值不符 命周期无效并完整重
er=hermes; plugin=null; chat_template=固定模型 tokenizer 内置模板; content_format=string; template_kwargs={}; structured nmar; reasoning_parser=null。	B0/B1 规范化值相同; 实际 CLI、生效回执 后 ordered token IDs/h
reasoning/structured/code: TTFT mean≤1000ms、p95≤2000ms、p99≤4000ms; TPOT mean≤40ms、p95≤60ms、p99≤80ms。long: 8192 /12/16s, 16384 输入≤16/24/32s; TPOT≤40/60/80ms。	各 rate 测量 600s; 完 99%; 样本少于 1000 时 error_rate≤0.1%; 值 不插值或外推。
独占 910B2 上执行 ascend-dmi FP16 算力测试 3 次所得 TFLOPS@FP16 中位数。effective_compute_spec v1: MatMul 按 2MNK, 逐批求和, Attention 计入 QK^T 和 PV, 其他逐元素算子不计入有效 FLOPs。	主形状 MFU≥90%; e msprof 总量误差≤3% msprof 输出全部保留。
68=渲染后输入 30720+输出 2048; 业务文档按 document_id 稳定排序循环拼接, 段间使用固定分隔符; 插入可核验目标事实, oracle 、无截断和 2048 输出 token。监控间隔=1s。	记录 HBM 已用/峰值 队列深度、请求 token 和吞吐; 任一字段缺
成本=资产原值÷21600 小时×生命周期小时; 电费=实测平均功率 kW×生命周期小时×0.60 元/kWh; 人工不计入机器运行成本并单列。 出 token 成本=全生命周期成本÷成功输出 token×10^6。	各比较关系使用同一 计费周期和功耗采样 测量期成本及五租户
THREADS=1; cpu_binding_policy=topo_affinity; CPU 核表根据所分配 NPU 的 NUMA 节点确定; streaming=true; clock=monotonic。	核表和实际亲和性 TTFT 取首个有效输出 token 间隔; 不得扫描 议。
作为任务书 7B—13B 代表模型的等效验收模型; 32K 定义为单次请求渲染后输入与输出合计 32768 token, 其中输入 30720、输出	上述两项口径作为本
提交 =91bcc4154b70333d87c8180afe85dc933452e253 ; 指标矩阵 6=bb386cd1e5f34bd79af9fb871d6cfa739cab80145149fc3b675daa6b310c2927; 理 注 册 表 6=18a32489d16467221362af11fb525760fda1c7b5fb56505569829ccaeb3f79fd ; 重数据/轨迹家族。	请求物化前核 及 metric tier 适用填 N/A, 主 具体阻塞 CANNOT_DE 不得将空值或 过。

固定值或绑定规则	生效日期

表附-9 证据包签名与发布门禁

字段	固定规则	执行要求
artifact hash	SHA-256	每个 artifact 记录 path、size、SHA-256
manifest canonicalization	RFC 8785 JCS	对规范化 manifest 计算 root hash
result signature	Ed25519 / RFC 8032	评测服务在证据包关闭写入后签名；任何字节变化均失效
signature scope	manifest root hash	覆盖 request ID、target/config version、B0/B1 identity、环境/NPU receipt、全部重复及中位数选择
admission	signature_verified=true	只有验签通过的 bundle 可进入验收报告、snapshot 和 website
key custody	评测服务根账户专有，权限 0400	worker 经最小权限 signing helper 使用；CI 和提交者不可读取私钥
trust store	公钥、key ID、有效期、撤销状态	旧公钥保留以验证历史包；实际 key ID、公钥指纹和 trust-store hash 由签名服务写入配置版本
request authentication	HMAC 仅用于请求	不得替代服务器结果签名

表附-10 第三方测试机构逐步执行清单

步骤	第三方操作	通过条件与留存证据
1 接收	接收 V4.6、第三方文档包、指标矩阵、物理资产注册表、配置清单和签名公钥；计算文件名、大小和 SHA-256	方案与资产 manifest 一致；生成接收清单和校验日志
2 隔离	进入维护状态，检查 910B2 型号、单卡独占、主机进程、磁盘、模型和数据容量	无其他 NPU 进程；记录设备序列号、驱动、固件、CANN、torch_npu 和 NPU assignment
3 工件	逐文件核验 FP16 模型、tokenizer 和 manifest；W8A8 扩展存在时另核算量化配置和质量回执	全部 hash 一致；质量达到表 4-3 和表附-8 门槛；保存逐题结果和聚合结果
4 数据	按表 4-5 核验 A1—A4 数据集组 manifest、44 个物理 dataset_id、test_tier、来源与授权、split/规模、转换程序及 oracle/scorer	case_id、顺序、内容/token hash、授权记录和程序 revision 全部一致
5 镜像	分别核验 B0、B1 exact refs、clean-overlay 证明、OCI digest/labels；禁止 dirty tree	B0 固定提交匹配；B1 与本次发布绑定；镜像和环境 manifest 完整

步骤	第三方操作	通过条件与留存证据
6 配置	adapter 按表附-2 至表附-7 生成 P0 及 A1—A4 FP16 配置；W8A8 扩展生成独立配置、comparison_id 和 config_id	禁止人工编辑；各 comparison_type 严格执行表附-1 角色合同，不得出现表外字段差别
7 启动	按共同配置启动两侧服务，等待健康检查；按表附-3 升序预捕获全部 capture sizes；采集 startup effective receipt 并逐项核验量化、缓存、分块预填充、eager 或 FULL_DECODE_ONLY 及资源参数	全部生效值符合表附-3；任一侧图未捕获或回退 eager 时停止生命周期并保留失败证据
8 连通	每个 profile 发送 1 条固定请求，验证协议、流式计时、日志、监控、停止和证据写入	仅作为连通性检查，不进入性能统计；不得据此改参
9 A1	按 A1-FP16 执行 B0 和 B1 各 3 个冷启动—预热—测量—停止生命周期，并完成 ascend-dmi 与 msprof 复核	主形状 MFU、计量误差、三次原始结果和中位数选择记录齐全
10 A2 容量	依次执行 DIALOGUE、TOOL、REASON、STRUCT、LONG 和 CODE 数据集组；同组 REQUIRED 数据分别出具结果；完成 A2-V 模态适用性判定；B0-FP16 和 B1-FP16 各 3 生命周期	服务参数在整条曲线中不变；每点请求数、SLO、错误、资源和机制指标齐全
11 A2 共同负载	以 B0-FP16 三次容量中位最大合规点计算 dialogue/tool 的 70% 负载，生成并签名到达序列；B0-FP16 和 B1-FP16 各运行 3 生命周期	B0/B1 复用相同请求和 arrival；形成 FP16 必测结论；W8A8 量化增量、同量化结果和端到端系统结果仅在扩展工件齐全时分别形成
12 A3	按 A3-32K-FP16 执行 B0/B1 各 3 生命周期，检查 6 个窗口、HBM/KV、输出 token、OOM、死锁和截断；W8A8 扩展单列	达到表 4-2 稳定性门槛；全部窗口和逐请求记录齐全
13 A4	先按固定输出 token 速率点执行 B0-FP16 三次混合容量扫描并生成 70% 正式负载，再执行 B0-FP16 和 B1-FP16 正式混合各 3 次；W8A8 扩展单列	完成成本、公平性、份额、尾延迟、利用率和隔离 B0 复核
14 汇总	按每阶段预声明主指标选择三次中位数；失败、取消、超时、替补和追加运行全部保留	不得逐指标挑最好；形成 repeat suite 和 canonical selection 记录
15 签发	关闭证据包写入，生成 JCS manifest、SHA-256 根哈希并以 Ed25519 签名；复算 A1—A4 并出具报告	signature_verified=true；报告逐项给出通过/不通过/不具备判定条件及证据路径

表附-11 正式测试包目录与文件命名

目录或文件	必须包含	校验与权限
-------	------	-------

目录或文件	必须包含	校验与权限
/plan/	V4.6 DOCX、PDF 和 SHA256SUMS；文件名含版本号，不得覆盖旧版本	只读；test_plan_sha256 写入每个请求、配置和结果 manifest
/registry/	targets-v4.1.yaml、schema.json、registry-version.txt；每个 target 含 active 状态	UTF-8、LF；JSON 按 RFC 8785 规范化；YAML 解析后转 JCS 计算 SHA-256
/images/{b0,b1}/	OCI manifest、repo digest、labels、软件清单和 clean-overlay 证明	正式运行只按 repo digest 拉取；tag 仅显示，不作为身份
/models/qwen25/{fp16,w8a8}/	model-manifest.json、tokenizer-manifest.json、全部分片 size/SHA-256 和 revision	目录只读；启动前逐文件校验；缺失或多出文件均拒绝
/datasets/<cell>/	source-manifest.json、cases.jsonl、ordered-case-ids.txt、rendered-token-hash.json	数据、顺序、模板和 tokenizer 绑定；B0/B1 字节一致
/oracles/<cell>/	判定程序、依赖锁文件、revision、入口命令和测试向量	离线运行；输出 oracle-result.json；代码和依赖均计算 SHA-256
/arrivals/<target>/	每个 repeat 与 rate 的单调时钟偏移序列、请求映射和 SHA-256	B0/B1 复用同一文件；不得运行时按 seed 重新生成
/configs/<comparison_id>/<role>/<config_id>/	external-contract.json、normalized.json、server-argv.json、client-contract.json、env.json、checksums.txt	comparison_id 绑定 comparison_type 及两侧角色化合同；B0/B1 config_id 分别绑定代码/镜像身份；目录只读
/runs/<request_id>/	按 target/role/repeat-N 分层保存原始请求、响应、日志、监控、回执和判定结果	每次运行新建目录；禁止覆盖、删除失败或复用旧输出
/reports/ 与 /signatures/	正式报告、artifact-manifest.jcs、manifest.sha256、Ed25519 签名、key-id 和验签结果	签名后关闭写入；任何字节变化均使验签失败

表附-12 独立评测机建设与交付验收

验收阶段	操作与固定要求	通过证据
硬件盘点	记录主机序列号、910B2 设备序列号、卡数、HBM 容量、CPU 型号、NUMA、内存和磁盘；执行 npu-smi info、lscpu -J、numactl -H、free -b、lsblk -J	命令原始输出、设备拓扑图和 hardware-manifest.json 三者一致
基础软件	记录 OS、kernel、firmware、driver、CANN、Python、torch、torch_npu、容器运行时；版本由命令直接采集	environment-manifest.json 无空值；B0/B1 使用同一宿主环境

验收阶段	操作与固定要求	通过证据
目录与权限	软件安装于 /opt/vllm-hust-evaluation; 配置 位于/etc/vllm-hust-evaluation; 模型、数据、队列和证据位于 /data/vllm-hust-evaluation; 服务 账户无交互登录权限	root 拥有配置和签名私钥; worker 只可写本次 run 目录; 路 径不存在或权限过宽即不通过
镜像与离线资产	按 OCI digest 预拉取 B0/B1 镜 像; 模型、数据、oracle、arrival 文件预置本地; 正式阶段关闭 在线下载	离线状态完成全量 SHA-256 校 验; 缺资产时在启动前失败
资源独占	每张 NPU 使用进程锁和文件 锁; 分配前检查设备进程、显 存、健康状态; 正式任务不得 终止或接管既有进程	同一设备并发分配为 0; 资源忙 保持 QUEUED, 不判代码失败
CPU 与 NUMA 绑定	设备到 NUMA 和 CPU 核表由一 次资格化生成并封存; OMP_NUM_THREADS 和核表 写入配置; 正式测试不再扫描	启动回执记录实际亲和性; 跨 NUMA 或核表不符即拒绝测量
时间与监控	系统时钟同步偏差不得超过 1 s; 客户端和服务端使用 CLOCK_MONOTONIC_RAW 或 等价单调时钟; NPU/HBM/CPU/RAM/磁盘每 1 s 采样	time-receipt.json、监控原始序列 连续; 正式窗口缺点率不得超 过 0.1%
服务与网络	Evaluation API 仅通过受控网络 入口访问; 模型 API 绑定调度 器签发的本机隔离地址和端 口; api_server_count=1; 正式执 行期间禁止外部流量	端口占用检查、访问控制测试、 健康检查和审计日志通过
维护与恢复	服务默认 maintenance=true; 完 成配置校验与封存后按 target 启用; 磁盘不足 20%、设备异 常、签名服务异常或时钟失同 步自动进入维护模式	故障注入后停止接单且保留在 途证据; 恢复须人工复核并留 审计记录
交付验收	用虚构 fixture 验证鉴权、幂等、 排队、取消、超时、锁、证据 封存、签名和 fail-closed; 不得 使用该结果作性能证据	建机验收单由建设方、测试方 各一人复核; 全部条目通过后 方可接收正式请求

表附-13 正式 target 与唯一配置版本结构

字段组	固定字段	生成与拒绝规则
-----	------	---------

字段组	固定字段	生成与拒绝规则
方案身份	test_plan_version=V4.6; test_plan_sha256; registry_version; target_id; profile_id	任一值不匹配 registry 即拒绝; 方案升级必须生成新 config_id
比较身份	baseline_role 仅 B0 或 B1; comparison 仅 B0_vs_B1; B0 core/plugin 固定为正文值; B1 绑定本次交付 exact SHA	B1 不得取 branch、tag 或 latest; dirty tree、未签提交或 SHA 空 缺即拒绝
镜像与模型	B0/B1 OCI repo digest、labels; 模型 revision、tokenizer revision、 分片 manifest SHA; FP16 或 W8A8 profile	本地 image ID 或目录名不能替 代 digest/manifest; profile 精度 与表附-3 不符即拒绝
服务配置	表附-2 至表附-4 全部规范化字 段、完整 compilation_config、环 境变量和服务前端字段	所有字段必须显式出现; null 表示有意关闭; 不得采用版本 默认值
客户端合同	表附-5 至表附-7 全部请求字 段、数据 manifest、oracle、arrival、 SLO、timeout 和 repeat	HTTP body 只发送 endpoint 支持 字段; 同时保存 normalized 请求 和 rendered wire request
调度字段	priority、quota、requested_cards、 exclusive=true、queue_timeout、 run_timeout、idempotency_key	idempotency_key=SHA-256(requ ester+target_id+config_id+compa rison+submission_nonce); 重复 提交返回同一 request_id
动态回执	request_id、hostname、物理 NPU 序列号、设备号、端口、开始 结束时间、CPU 核表	不作为性能分组差异; 必须签 入证据包; 调度器签发后不得 由提交方改写
配置标识	comparison_id=SHA-256(JCS({ 方案、comparison_type、硬件、 两侧角色化模型/量化工件、固 定服务配置、数据、请求、 arrival、采样、SLO、质量、周 期、成本口径}); config_id=SHA-256(JCS({compar ison_id、角色、代码、镜像、环 境、角色化模型与量化字段}))	同一 comparison_id 的 B0/B1 角 色合同必须匹配表附-1; FP16 必测线除代码提交、镜像身份 和角色标识外使用同一规范化 配置; W8A8 扩展仅允许固定工 件、served_model_name 和 quantization 三项按角色合同取 值, 不得现场增加其他差别或 例外
激活门禁	active=false 为初始状态; 完整资 产校验、资格化回执、签名信 任链和配置双人复核后改为 true	未完成任一前置项不得生成正 式运行令牌; active 状态变化写 审计日志

表附-14 服务启动、请求生成与生效值校验

步骤或字段	唯一映射	执行检查
-------	------	------

步骤或字段	唯一映射	执行检查
命令生成	adapter 读取 normalized.json 并生成 argv 数组，不拼接 shell 字符串；server-argv.json 逐项保存参数名和值	未知字段、重复字段、不能映射字段或不支持的组合立即 BLOCKED_CONFIG
模型与精度	model_path 来自已校验 manifest；dtype=float16；FP16 时 quantization=null 且不传量化参数；W8A8 时传--quantization ascend	启动回执必须分别显示 dtype=float16、quantization=None 或 ascend；与 profile 不符即停止
并行与容量	TP/PP/DP/DCP、block_size、max_model_len、gpu_memory_utilization、max_num_seqs、max_num_batched_tokens 按表附-2 和表附-3 映射	服务日志和 metrics 导出的 effective 值逐项匹配；不允许自动缩小 max_model_len 或 batch 上限
缓存与调度	prefix caching、chunked prefill、FCFS、swap=0、CPU offload=0、speculative/MTP 和 cudagraph 严格按 profile 映射	未列出的推测解码、量化、缓存或图模式一律不得启用；不允许启动失败后降级
OpenAI 前端	host 和 port 由调度器签发；api_server_count=1；chat 类 endpoint=/v1/chat/completions；A1 使用/v1/completions	health/startup/graceful-shutdown timeout 均取配置值；端口和 hostname 仅记回执，不形成新规格
工具调用	A2-TOOL 和 A4 工具租户统一启用 auto tool choice、同一 tool_call_parser、plugin 和 chat_template；parallel_tool_calls=true	B0/B1 启动参数、模板字节和渲染 token hash 一致；非工具请求不发送 tools 相关字段
结构化输出	structured_outputs_backend 及 disable_any_whitespace、disable_additional_properties 在资格化后固定为具体值；禁止 auto	每次启动读取 effective backend；每个请求保存 response_format/json_schema 原文和 hash
规范化与 wire 字段	ignore_eos 位于客户端：A1/A3=true，A2/A4=false；Completion 与 Chat 分别按表附-5 生成 logprobs 字段；best_of、detokenize 等 normalized-only 字段不作为不支持的 HTTP extra 发送	保存每个唯一请求体、header 白名单、rendered body 及 SHA-256；服务端静默忽略字段视为配置失败

步骤或字段	唯一映射	执行检查
启动顺序	校验方案与资产→获取独占锁→写入 env→生成 argv→启动容器→轮询 health→采集 effective receipt→单请求连通性检查→预热→正式测量	任一步失败不进入下一步；连通性请求单独标记 commissioning，不混入统计
容量扫描	只改变客户端 arrival rate；服务进程、argv、env 和 config checksum 在完整 rate 序列中保持字节一致；rate 按表附-6 升序且不退	每个 rate 前后记录 checksum；发现服务重启或参数变化则该生命周期无效并完整重跑

表附-15 数据 manifest、确定性选样与请求身份

负载	确定性规则	必须保存
统一规范	文本转 UTF-8、Unicode NFC 和 LF；JSON 按 RFC 8785 规范化；case_key=SHA-256(dataset_revision case_id normalized_content)；按 case_key 升序选取，不随机抽样	source URI、许可记录、revision、原文件 SHA-256、过滤日志、入选与排除 case 清单
通用问答/多轮	DIALOGUE-PUBLIC：合法公开或授权的完整指定分片，不少于 20000 条有效请求；保留非空 user/assistant 及原始顺序，最后 assistant 可仅作为标准答案移除；转换后以 user 结束；不按内容、语言、长度、主题或性能筛选	数据名称、来源、许可、revision、原始数量、可执行数量、排除原因；requests 与 schedules 文件、转换日志、messages、token IDs 及总体 hash
工具调用	TOOL-PUBLIC：不少于 512 个可判定用例；单工具、多工具/并行和多轮均有覆盖；真实 tools schema 必须可由冻结 parser 加载	全部 case、tools 原文、期望 tool name/arguments、轮次状态、oracle、parser、覆盖统计和文件 SHA-256
推理	REASON-PUBLIC：不少于 1000 个确定答案用例；答案抽取失败、超时、空响应均计失败；不得按难度、题型或运行结果排除	全部题目、标准答案、抽取结果、原始文件 SHA-256、ordered token hash 及逐例结果
结构化输出	STRUCT-PUBLIC：不少于 60 个 schema；覆盖对象、数组、枚举、嵌套、约束和引用；dialect 及外部引用资格规则在执行前固定，全部入选 schema 均执行	schema 原文、dialect、覆盖统计、资格化日志、prompt、校验器版本、渲染 token hash 及逐例结果

负载	确定性规则	必须保存
A2 长上下文容量	LONG-PUBLIC: 不少于 64 篇具有可核验目标事实的授权文本；按 document_id 与内容 hash 排序，确定性窗口化生成 16 条 8192+512 和 16 条 16384+1024；不使用随机 token	来源段落范围、拼接映射、截取边界、输入/目标 token 数、输出 oracle 和 ordered hash
A3 32K	LONG-PUBLIC 确定性生成总上下文 32768=30720 输入+2048 输出的最多 64 条请求；禁止把 32768 输入再附加输出	每条输入精确 token 数、文档段落映射、最大 64 条清单、输出 oracle 和总体 hash
代码	CODE-GROUP : InstructCoder 、 LiveCodeBench 三类 split、HumanEval、MBPP 和 SyFi 按冻结官方版本完整执行； PAIO-CODE-EVAL 仅作扩展引用； OpenCode/SWE-bench 生产优化轨迹单列。	原始任务与测试、编译器 / 容器、官方 scorer 版本、逐例代码/编译/测试结果、失败类型、token 与时延、文件和结果 SHA-256
A4 多租户	五租户分别引用已冻结的 dialogue、tool/agent、reasoning、structured、code 清单；按目标输出 token 投递份额各 20%；同一物理数据不复制、不重新抽样	dataset_id、tenant、record/session 标签、目标 token 预算、预生成 arrival 时间戳、request_id 和 case_id 一一对应表

负载	确定性规则	必须保存
token 与截断	只用冻结 tokenizer、chat_template 和 template kwargs 渲染；add_special_tokens 及 generation prompt 按表附-5；truncate_prompt_tokens=null，任何超长样本在资产制作阶段排除	原始内容 hash、rendered body hash、ordered token IDs hash 和实际服务端 prompt token 计数
复用规则	同一 cell、rate 和 repeat 的 B0/B1 使用同一 ordered case 和 arrival 文件；case 循环到 request cap，不重抽、不重排	每个请求的 case 序号、名义发送时刻、实际发送时刻、send lag 和响应关联 ID

表附-16 评测任务状态机、排队与生命周期

状态	进入与退出条件	系统动作
RECEIVED	API 鉴权、请求签名和幂等检查通过后进入 VALIDATING	生成 request_id；原始请求只读保存
VALIDATING	校验 test_plan_sha256、target active、config_id、资产、OCI、签名信任链和配额	任一缺失转 BLOCKED_CONFIG；不得生成启动命令
QUEUED	校验通过但资源尚未分配；按 priority、提交时间排序	资源忙保持 QUEUED；排队不计 run timeout；心跳和队列位置可查询
ALLOCATING	取得所需 NPU 与 CPU 独占锁并完成设备预检后进入 STARTING	锁冲突回 QUEUED；设备异常转 INFRA_FAILED 并进入维护模式
STARTING	按表附-14 启动并在 startup timeout 内通过 health 和 effective receipt	启动错误或参数不符停止服务；保留完整日志；不得改参重启
WARMUP	连通性检查通过后执行本 cell 固定预热；预热数据单独标记	预热结束清零测量计数但不删除日志；预热失败按正式失败保留
MEASURING	按冻结 arrival、时长、request cap 和 timeout 执行；每 30 s 写心跳	心跳中断 120 s 转 INFRA_FAILED；请求失败、OOM 和截断计入本次结果
STOPPING	测量结束、失败、超时或取消后执行优雅停止；超时后强制终止仅限本任务进程	记录退出码、残留进程和释放时间；不得影响其他任务
PACKAGING/SIGNING	关闭运行目录写入，生成 artifact manifest、复算全部 hash 并由服务端签名	证据缺失转 FAILED_EVIDENCE；签名后目录不可修改
VERIFIED	公钥、有效期、撤销状态和全部 artifact hash 校验通过	按表附-18 运行自动判定；只有此状态可进入报告

状态	进入与退出条件	系统动作
PASSED/FAILED	所有硬门槛通过为 PASSED; 任一硬门槛失败为 FAILED	失败不自动重跑、不替换、不从中位数集合删除
BLOCKED_CONFIG/INFRA_FAILED/CANCELLED/TIMEOUT	分别表示配置不完整、设施故障、授权取消和运行超时	均不得放行 merge/release; 修复后创建新 attempt 并保留原 attempt; 仍须取得 3 次有效生命周期

表附-17 异常分类与复测处置

异常	分类与当次结论	处置
hash、digest、revision 或签名不符	BLOCKED_CONFIG; 未开始正式测量	更正资产或发布新 config_id; 禁止绕过校验
未知 CLI、字段被忽略、effective 值不符	BLOCKED_CONFIG; 配置不可执行	修订 adapter 或方案版本; 不得删除字段、采用默认值或降级启动
服务启动失败或不健康	固定配置导致则 FAILED; 宿主故障导致则 INFRA_FAILED	依据启动日志和设备健康证据分类; 任何复测均保留原 attempt
OOM、死锁、进程退出、请求错误	工作负载触发时计测试失败	不得降低并发、长度、显存利用率或改精度; 停止该生命周期并完整留证
静默截断、token 数不符、非法协议	对应请求失败; 触发质量或正确性门槛	保存 wire request、原始响应和 token 计数; 修复后从 repeat 1 完整重跑
客户端迟发或并发饱和	请求进入本地 FIFO, 保留名义时间与 send lag; 不丢弃、不重排、不突发追赶	超过 cell timeout 计失败; 不得以实际发送速率替代名义投递负载
监控缺失或采样断点超过 0.1%	FAILED_EVIDENCE; 利用率、稳定性和成本不可判	修复采集链后新建 attempt; 原性能数据不得单独采用
磁盘满、掉卡、宿主重启、时钟异常、网络中断	INFRA_FAILED	进入维护模式; 恢复检查通过后增加 replacement attempt, 不覆盖原记录
三次结果波动异常	原三次全部保留; 按正文方差规则最多追加 2 次	追加不能替换原值; 中位数从预声明完整集合计算, 不挑最好
人工取消	CANCELLED, 未通过	保留取消人、原因和时间; 重新执行须创建新 attempt 并从服务冷启动开始
B0 与 B1 请求、arrival 或出现表附-1 未明确列出的配置差别	比较无效, BLOCKED_CONFIG	重新生成同一 config version 下的两侧合同; 不得对结果做事后归一化

异常	分类与当次结论	处置
证据包验签失败	FAILED_EVIDENCE	禁止进入验收报告、snapshot 或 website; 从原始只读副本重新封包并保留失败包

表附-18 指标计算、重复选择与自动判定

指标或步骤	计算规则	判定约束
时间基准	所有时间戳使用单调时钟纳秒值; latency=t_last_response-t_actual_send; TTFT=t_first_token-t_actual_send; output_tokens 含服务返回的全部生成 token	不得用墙钟跨主机相减; 排队 send lag 另报, 不从服务时延中删除
TPOT	output_tokens>1 时, TPOT=(t_last_token-t_first_token)/(output_tokens-1); output_tokens=1 时记 not_applicable	单位统一 ms/token; 不得以 ITL 均值替代, 原始 token 时间戳同时保留
吞吐与 goodput	output TPS=成功输出 token 总数/测量墙钟秒; request TPS=成功请求数/测量墙钟秒; SLO goodput=同时满足正确性和该 cell 全部 SLO 的请求数/秒	预热、cooldown 不入分母; 正式窗口内错误请求占用的时间不得扣除
分位数	对请求级指标升序排列, 采用 nearest-rank: rank=ceil(p × N), 取第 rank 个值; 报告 mean、p50、p95、p99	禁止插值; N 和缺失值数量必须随指标报告
重复与中位数	每个 cell 至少 3 次独立冷启动生命周期; 先在每次内部计算主指标, 再对生命周期主指标取数值中位数; 偶数追加后取中间两值平均	整次生命周期作为选择单元; 不得把不同 repeat 的请求拼接后取中位数, 不得挑最好 repeat
A1 MFU	MFU=effective_model_FLOPs/(测量墙钟秒 × 表 4-12 规定的 910B2 FP16 峰值); 4096 × 8 为唯一主形状; 与 msprof 算子 FLOPs 偏差不超过 3%	只用未经四舍五入的值判定; 辅助形状只作护栏, 不可替换主形状

指标或步骤	计算规则	判定约束
A2 容量	每个预定义 rate 点同时满足绝对 SLO、质量和错误门槛才合规；最大合规容量为最高合规预定义 rate；不插值、不外推	dialogue 和 tool 按 B1-FP16/B0-FP16 执行容量 ≥ 2.0 及共同负载 TTFT、TPOT 各改善 $\geq 20\%$ ；P0 全量结果如实报告，不用单次全量固定 rate 替代容量判定；W8A8 扩展单列
质量	FP16 质量百分点差 =B1-FP16-B0-FP16；W8A8 量化增量=B1-W8A8-B1-FP16； B0 原生兼容时另算同量化差。 Schema 合法率=合法 JSON 且满足 schema 的响应数/全部请求； 工具成功率=tool name 和 arguments 通过官方 oracle 的请求数/全部请求	协议错误、超时、空响应和截断均计失败；性能结果不得抵销质量失败
A3 稳定性	窗口吞吐 CV=标准差/均值；漂移=(当前窗口指标-首个稳定窗口指标)/首个稳定窗口指标；分别计算 median 和 p99	6 个 5 min 窗口、CV $\leq 5\%$ 、median 漂移 $\leq 10\%$ 、p99 漂移 $\leq 20\%$ ，且样本少于 1000 时 0 失败
A4 公平性	$Jain = (\sum g_i)^2 / (5 \times \sum g_i^2)$ ， g_i 为租户实际 goodput/投递 goodput；服务份额=租户成功输出 token/五租户成功输出 token 总数	$Jain \geq 0.90$ ；各份额相对 20% 偏差 $\leq 10\%$ ；逐租户 p99 和质量不得被平均掩盖
成本	单位成本=完整生命周期成本/成功输出 token 数 $\times 10^6$ ；计时从服务启动到停止；B0/B1 采用同一价格、能耗和分摊口径	FP16 必测降低比例 =(B0-FP16-B1-FP16)/B0-FP16； W8A8 扩展分别计算量化增量和端到端系统结果；不得混写为纯框架收益
自动判定顺序	①证据与签名有效；②三次有效生命周期齐全；③正确性和质量通过；④逐 repeat 计算；⑤取主指标中位数；⑥执行 A1—A4 硬门槛；⑦生成 verdict.json	任一硬门槛为 false 则 FAILED；证据或样本缺失为 CANNOT_DETERMINE；不得用其他 cell 的提升补偿
计算示例	若 dialogue 的 B0/B1 最大合规容量为 2/4 RPS，容量比=2.00；共同负载 TTFT 为 800/600 ms，改善 25%；TPOT 为 50/38 ms，改善 24%	三项均达到对应阈值；该数值只说明计算方法，不作为预期结果或宣传数据
跨场景几何平均	对预先冻结的 A2 与	任 一 适 用

指标或步骤	计算规则	判定约束
	A4 所有适用 REQUIRED dataset_id×config_id 吞吐比等权计算： $GM = \exp[(1/K) \sum \ln(R_{Q,k})]$ SUPPLEMENTARY 与 N/A 不进入 K	REQUIRED 结果缺失、FAILED 或 CANNOT_DETERMINE 时，GM 不得形成通过性结论；不得在看到结果后改变场景集合或权重

表附-19 报告、证据包和现场复核

交付项	必须内容	完成标准
报告首页	项目名称、方案版本与 SHA-256、测试机构、测试地点、起止时间、config_id、B0/B1 exact 身份	任一身份不得用简称、分支或 tag 代替
环境与资产	硬件、OS、driver、firmware、CANN、torch_npu、容器 digest、模型与数据 manifest、CPU/NPU 绑定	与签名 receipt 逐项一致；全文只引用一个 config version
执行记录	A1、A2 六个执行单元、A2-V 适用性、A3、A4 逐项列出 3 次及追加 repeat；含启动、预热、测量、停止时间和退出码	失败、超时、取消、replacement 均单列，不得只呈现成功结果
指标结果	每次 repeat 原始指标、生命周期中位数、B0/B1 比较、质量、SLO、稳定性、公平性、利用率和成本	保留未舍入机器值；表格显示值不得参与二次判定
判定说明	逐条列出 P0、A1—A4 门槛、实际值、布尔结果和证据路径；结论词仅 PASSED、FAILED、CANNOT_DETERMINE、NOT_EXECUTED_OPTIONAL、INTERNAL_VERIFIED	必须交付任一项 FAILED 或 CANNOT_DETERMINE 时，不得给出整体验收通过

交付项	必须内容	完成标准
启动参数一致性	B0-FP16 与 B1-FP16 规范化性能配置除代码、镜像和角色标识外差异为 0；P0 及 A2—A4 均使用 FULL_DECODE_ONLY 及相同 capture sizes；W8A8 扩展只允许固定工件、服务名和 quantization 变化	发现任何表附-1 未明确列出的配置差别、任一侧未实际启用图执行或偏离固定配置即判比较无效；不得写解释性豁免
证据索引	artifact-manifest.jcs 列出全部相对路径、size、SHA-256、生成角色、request_id、target、repeat 和 median selection	清单无悬空文件、重复路径或未列文件；全包复算通过
签名验证	Ed25519 签名、key-id、公钥指纹、trust-store revision、有效期与撤销状态、signature_verified	signature_verified=true 方可签发报告；请求 HMAC 不能替代结果签名
复算交付	随包提供只读的公式说明、oracle 入口和 verdict.json；第三方从 raw 数据复算后与报告逐项比对	复算差异必须为 0；不一致时报告暂缓签发并保留两份结果
现场复核	测试执行人、数据复核人、环境管理员分别填写姓名、单位、日期和签字；测试机构加盖报告章	执行、复核不得由同一人兼任；签字页与电子签名证据一并归档
文件命名	正式报告：项目简称_V4.6_<config_id 前 12 位>_验收测试报告.pdf；证据包：同前缀_evidence.tar.zst；校验文件：同前缀_SHA256SUMS	文件名、报告内 config_id 和签名 manifest 一致；禁止覆盖同名历史文件
归档与发布	原始证据、报告、签名和验签记录进入不可变存储；website/snapshot 只读取 VERIFIED 且结论允许发布的 bundle	保留期限按项目档案制度执行；后续复测生成新 request_id 和新包

生效规则：表附-1 至表附-19 共同构成本次验收依据。每次正式测试将 B0/B1 exact 提交、镜像摘要、模型清单、数据与到达序列、物理设备、实际命令、运行环境和签名身份归集为唯一 comparison_id，并为各角色生成 config_id。正式队列只接受 B0、B1 及 B0_vs_B1；固定值不完整、角色合同不匹配、记录缺失、生效校验或签名失败时，不得开展测量或形成验收结论。